

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Aleks Muhič

**Razvoj in vrednotenje sistema za
zaznavanje nevarnih zvočnih
dogodkov na mikrokrmilniku
STM32N6 z uporabo nevronskega
pospeševalnika**

DIPLOMSKO DELO

VISOKOŠOLSKI STROKOVNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE

MENTOR: viš. pred. dr. Robert Rozman

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Programska oprema v javnem repozitoriju vključuje lastno programsko kodo in komponente tretjih oseb. Posamezne komponente ostajajo pod licenčnimi pogoji, navedenimi v datotekah `LICENSE` v repozitoriju; to velja zlasti za programsko opremo podjetja STMicroelectronics, na kateri temelji izvedba.

Besedilo je oblikovano z urejevalnikom besedil $\text{\LaTeX}$.

Kandidat: Aleks Muhič

Naslov: Razvoj in vrednotenje sistema za zaznavanje nevarnih zvočnih dogodkov na mikrokrmilniku STM32N6 z uporabo nevronskega pospeševalnika

Vrsta naloge: Diplomaska naloga na visokošolskem programu prve stopnje

Mentor: viš. pred. dr. Robert Rozman

Opis:

Cilj diplomskega dela je razviti in ovrednotiti vgrajeni sistem za sprotno zaznavanje nevarnih zvočnih dogodkov na razvojni plošči STM32N6570-DK. Sistem je zasnovan kot prototip vidnega opozarjanja za gluhe in naglušne osebe, pri čemer se zvok obdeluje lokalno brez dostopa do računalniškega oblaka in brez trajnega shranjevanja surovih zvočnih posnetkov. Kandidat bo prilagodil kvantizirani model na osnovi arhitekture YAMNet za izvajanje na mikrokrmilniku STM32N6 z nevronskim pospeševalnikom Neural-ART ter povezal zajem zvoka, predobdelavo, sklepanje in prikaz rezultatov. Sistem bo ovrednotil z nadzorovanim preskusom na fizični napravi ter analiziral pravilnost zaznavanja, lažne alarme, čas izvajanja in porabo pomnilnika.

Title: Development and Evaluation of a Hazardous Sound Event Detection System on an STM32N6 Microcontroller with a Neural Accelerator

Description:

The aim of the thesis is to develop and evaluate an embedded system for real-time hazardous sound event detection on the STM32N6570-DK development board. The system is designed as a visual-alert prototype for deaf and hard of hearing users, with local audio processing, no cloud access, and no persistent storage of raw audio recordings. The candidate will adapt a quantized model based on the YAMNet architecture for execution on an STM32N6 microcontroller with the Neural-ART accelerator and integrate audio acquisition,

preprocessing, inference, and result presentation. The system will be evaluated through a controlled test on the physical device, including detection performance, false alerts, execution time, and memory usage.

Izdelava te diplomske naloge ne bi bila mogoča brez pomoči in podpore ljudi, ki so mi stali ob strani med študijem in razvojem projekta. Posebej se zahvaljujem mentorju viš. pred. dr. Robertu Rozmanu za strokovno usmerjanje in pomoč pri izdelavi naloge. Iskrena hvala tudi moji družini in najbližjim prijateljem za podporo, potrpežljivost in spodbudo. Zahvaljujem se tudi vsem profesorjem, ki so mi omogočili prijetno študijsko izkušnjo ter mi predali veliko znanja.

Kazalo

Povzetek

Abstract

1	Uvod	1
1.1	Motivacija in opredelitev problema	1
1.2	Cilji in raziskovalna vprašanja	2
1.3	Prispevki diplomskega dela	3
1.4	Struktura dela	4
2	Teoretične osnove in sorodna dela	5
2.1	Digitalni zvok in zajem signala	5
2.2	Časovno-frekvenčna predstavitev	6
2.3	Razvrščanje zvočnih dogodkov	8
2.4	YAMNet, prenos učenja in kvantizacija	9
2.5	Robna umetna inteligenca in nevronske pospeševalniki	12
2.6	Sorodna dela	13
3	Zasnova sistema	17
3.1	Funkcionalne in nefunkcionalne zahteve	17
3.2	Strojna platforma STM32N6570-DK	19
3.3	Arhitektura podatkovnega toka	19
3.4	Programska zgradba in zagonski tok	21
3.5	Nabor razredov in politika odločanja	22

3.6	Zasnova prikaza opozoril	22
4	Implementacija	25
4.1	Zajem in prenos zvočnih podatkov	25
4.2	Predobdelava zvočnega signala	28
4.3	Priprava in pretvorba modela	30
4.4	Izvajanje modela na Neural-ART	36
4.5	Razporeditev pomnilnika in zanesljiv zagon	38
4.6	Časovno filtriranje in zavračanje negotovih vhodov	40
4.7	Uporabniški vmesnik in diagnostični izhod	42
5	Metodologija vrednotenja	45
5.1	Cilji vrednotenja	45
5.2	Razvojni in ocenjevalni preizkusi	46
5.3	Rezervirani preizkus predhodne izvedbe	48
5.4	Sprejemni preizkus vmesne izvedbe	51
5.5	Ločeni končni fizični preizkus	52
5.6	Zajem podatkov in merila uspešnosti	54
5.7	Merjenje časa izvajanja in pomnilnika	55
5.8	Veljavnost in omejitve	56
6	Rezultati	57
6.1	Ločitev vrednotenih izvedb	57
6.2	Rezultati predhodnih izvedb	58
6.3	Končna izvedba YAMNet-1024	59
6.4	Čas izvajanja končne izvedbe	63
6.5	Pomnilniški in računski odtis končne izvedbe	64
7	Razprava in sklepne ugotovitve	67
7.1	Odgovori na raziskovalna vprašanja	67
7.2	Razprava o uporabnosti rezultatov	68
7.3	Omejitve	69
7.4	Možnosti nadaljnjega dela	69

7.5 Sklep	70
Literatura	73
A Sledljivost programske opreme in rezultatov	77

Povzetek

Naslov: Razvoj in vrednotenje sistema za zaznavanje nevarnih zvočnih dogodkov na mikrokontrolerju STM32N6 z uporabo nevronskega pospeševalnika

Avtor: Aleks Muhič

V diplomskem delu je predstavljen vgrajeni sistem, ki nevarne zvoke iz okolice pretvori v vidna opozorila. Zasnovan je kot raziskovalni prototip pripomočka za gluhe in naglušne osebe. Celotna obdelava poteka na razvojni plošči STM32N6570-DK, brez dostopa do računalniškega oblaka in brez shranjevanja zvočnih posnetkov. Zvok z vgrajenega mikrofona obdela prilagojeni model YAMNet-1024, ki se izvaja z nevronskega pospeševalnika Neural-ART. Sistem razpozna pasji lajež, razbitje stekla, strel in sireno, govor ter razred *drugo*; odločanje stabilizirajo razredni pragovi in časovno filtriranje. V ločenem končnem fizičnem preizkusu, neodvisnem od učenja modela, razvojnega vrednotenja ter izbire modela in pragov, je sistem pričakovani razred vsaj enkrat potrdil v 57 od 60 poskusov. Pravilni razred je bil prevladujoč v 54 od 60 poskusov. Pri varovalnih razredih se je lažni nevarnostni alarm pojavil v 6 od 20 poskusov, vseh šestkrat pri razredu *drugo*; isti poskus je lahko vseboval pravilno potrditev in lažni alarm. Obdelava vhoda, ki se pripravi vsakih 480 milisekund, je povprečno trajala 10,81 milisekunde. To potrjuje zadostno računsko zmogljivost za sprotno delovanje, celotni odziv pa vključuje še zbiranje zvočnega okna in časovno potrjevanje. Mediana časa do prve pravilne potrditve je zato glede na razred znašala od 1,00 do 2,50 sekunde.

Ključne besede: vgrajeni sistemi, zaznavanje zvočnih dogodkov, STM32N6,

nevronski pospeševalnik, robna umetna inteligenca, zasebnost.

Abstract

Title: Development and Evaluation of a Hazardous Sound Event Detection System on an STM32N6 Microcontroller with a Neural Accelerator

Author: Aleks Muhič

This thesis presents an embedded system that converts hazardous environmental sounds into visual alerts. It is designed as a research prototype of an assistive device for deaf and hard-of-hearing users. All processing runs on the STM32N6570-DK development board, without cloud access or storage of audio recordings. Audio from the onboard microphone is processed by an adapted YAMNet-1024 model running on the Neural-ART accelerator. The system recognizes dog barks, breaking glass, gunshots, sirens, speech, and the “other” class; class-specific thresholds and temporal filtering stabilize its decisions. In a separate final physical evaluation, held out from model training, development evaluation, model selection, and threshold selection, the system confirmed the expected class at least once in 57 of 60 trials. The expected class was the dominant confirmed output in 54 of 60 trials. A false hazardous alert occurred in 6 of the 20 guard-class trials, all six involving the “other” class; the same trial could contain both a correct confirmation and a false alert. Processing an input prepared every 480 milliseconds took 10.81 milliseconds on average. This demonstrates sufficient computational capacity for real-time operation, while the complete response also includes audio-window collection and temporal confirmation. Consequently, the class-wise median time to the first correct confirmation ranged from 1.00 to 2.50 seconds.

Keywords: embedded systems, sound event detection, STM32N6, neural accelerator, edge AI, privacy.

Poglavje 1

Uvod

1.1 Motivacija in opredelitev problema

Zvok nas pogosto opozori na nevarnost, še preden jo opazimo z vidom. Sirena, razbitje stekla, strel ali opozorilno lajanje psa pa niso uporabna opozorila za vsakogar. Pri nalogi me je zato zanimalo, ali je mogoče zvok iz okolice sproti pretvoriti v jasno vidno opozorilo za gluho ali naglušno osebo, brez uporabe oddaljenega strežnika. Nastal je prototip, ki celotno pot od mikrofona do prikaza izvede na eni razvojni plošči. Ne gre za certificiran pripomoček, ampak za praktičen preizkus takšne zamisli.

Tema me ni pritegnila le zaradi svoje uporabnosti. Želel sem tudi ugotoviti, kaj se zgodi, ko umetno inteligenco iz običajnega računalniškega okolja prenesemo na mikrokontrolnik z omejenim pomnilnikom. Razvoj vgrajenih sistemov se vse bolj usmerja v lokalno izvajanje umetne inteligence, razvojna plošča STM32N6570-DK pa omogoča, da tak pristop preizkusimo na resnični napravi [10, 18]. Projekt je bil zato tudi priložnost za učenje dela z novo generacijo mikrokontrolnikov in namenskim nevronskega pospeševalnikom.

Ker sistem ves čas posluša okolico, ni vseeno, kaj se zgodi z zajetim zvokom. Razviti prototip vso obdelavo opravi neposredno na razvojni plošči. Zvočni vzorci ostanejo v pomnilniku le med sprotno obdelavo, nato se zavrnejo. Program jih ne shranjuje in ne pošilja v računalniški oblak, med

vrednotenjem pa beleži samo napovedi in čase izvajanja. Tako lahko sistem deluje brez internetne povezave in ne ustvarja zbirke posnetkov iz uporabniškega okolja.

Lokalna obdelava pa ni brez zahtev. Naprava mora neprekinjeno zajemati zvok, pripraviti vhod za nevronske mreže, izvesti model in osveževati zaslon, ne da bi vmes izgubila nove vzorce. Kmalu se je pokazalo tudi, da dober model sam po sebi ni dovolj. Veliko časa je šlo v iskanje, poslušanje in opisovanje posnetkov, izrezovanje kratkih dogodkov ter gradnjo varovalnega razreda drugo. Brez tega bi sistem prepogosto opozarjal na nekaj, kar ni nevarno. Naloga zato obravnava celotno pot od učnih podatkov do zaznav in lažnih alarmov na fizični napravi.

1.2 Cilji in raziskovalna vprašanja

Glavni cilj je bil izdelati delujoč sistem na razvojni plošči STM32N6570-DK, ki z vgrajenim mikrofonom zazna izbrane nevarne zvoke in rezultat prikaže uporabniku na zaslonu. Razlikovati mora med nevarnimi dogodki, govorom, razredom drugo, negotovo napovedjo in stanjem čakanja. Hkrati sem želel praktično preizkusiti nevronske pospeševalnike Neural-ART in spoznati razvojni postopek za takšen mikrokrmilnik. Za končno preverjanje je bilo treba pripraviti še ponovljiv postopek vrednotenja, ki različico modela in programa poveže z izmerjenimi rezultati.

V nalogi odgovarjamo na naslednja raziskovalna vprašanja:

1. Ali je mogoče kvantizirani model za zaznavanje zvočnih dogodkov izvajati v realnem času na mikrokrmilniku STM32N6 z uporabo nevronskega pospeševalnika Neural-ART?
2. Kakšen delež potrjenih pravih zaznav in lažnih nevarnostnih alarmov doseže končni sistem pri nadzorovanem predvajanju zvokov na fizični napravi?

3. Kako se posamezni zvočni razredi razlikujejo po zanesljivosti in kateri dejavniki omejujejo delovanje sistema?

Vprašanja tako preverjajo tri plasti sistema: zmogljivost strojne opreme, celotno pot od predvajanega zvoka do prikazane odločitve ter razloge za razlike med zvočnimi razredi.

1.3 Prispevki diplomskega dela

Glavni prispevki dela so:

- povezava neprekinjenega zajema z vgrajenega mikrofona, digitalne predobdelave, modela YAMNet-1024 in nevronskega pospeševalnika v samostojno delujočo aplikacijo;
- zasnova sledljivega postopka za gradnjo učnega nabora, ki vključuje izbiro in poslušanje posnetkov, izrezovanje kratkotrajnih dogodkov, povečanje podatkov ter varovalna razreda govor in drugo;
- izvedba časovnega filtra s pragovi po razredih ter uporabniškega vmesnika, ki prikazuje trenutno in nedavne napovedi;
- lokalna zasnova brez pošiljanja zvoka v računalniški oblak in brez trajnega shranjevanja surovih zvočnih vzorcev v običajnem delovanju;
- sledljiv fizični preizkus s 60 novimi, slušno pregledanimi zvočnimi dražljaji, shranjenimi dnevniki, kontrolnimi vsotami in ponovljivo analizo rezultatov.

Prednaučeni izločevalnik značilk YAMNet ni nastal v okviru naloge. Težišče lastnega dela je drugje: v premišljeni izbiri in pripravi zvočnih podatkov, prilagoditvi modela ciljnim razredom, njegovi namestitvi na mikrokrmilnik, odločitvenih pravilih, prikazu ter eksperimentalnem vrednotenju celotnega sistema.

Pri jezikovnem urejanju je bil uporabljen ChatGPT podjetja OpenAI [11]. Orodje je služilo kot urejevalnik besedila za predloge slovničnih, slogovnih in izraznih izboljšav.

1.4 Struktura dela

Poglavje 2 najprej predstavi znanje, potrebno za razumevanje rešitve: digitalni zvok, melov spektrogram, nevronske mreže in kvantizacijo. V poglavju 3 so nato opredeljene zahteve, izbrana strojna platforma in tok podatkov. Osrednji praktični del je Poglavje 4, ki sledi poti zvoka skozi zajem, predobdelavo, model, nevronski pospeševalnik in uporabniški vmesnik. Poglavje 5 pojasni izvedbo preizkusov, Poglavje 6 predstavi meritve, v poglavju 7 pa so rezultati povezani z raziskovalnimi vprašanji, omejitvami in sklepnimi ugotovitvami.

Poglavje 2

Teoretične osnove in sorodna dela

Za razumevanje sistema je treba najprej slediti poti zvoka: od nihanja zračnega tlaka in digitalnih vzorcev do spektrograma ter odločitve modela. Poglavje zato predstavi zajem zvoka, časovno-frekvenčno predstavitev, model YAMNet, prenos učenja, kvantizacijo in izvajanje na robni napravi. Na koncu rešitev umesti med sorodne pristope.

2.1 Digitalni zvok in zajem signala

Zvok je sprememba zračnega tlaka, ki se širi po prostoru, mikrofoni pa jo pretvorijo v električni oziroma digitalni signal. Mikrokontroler namesto neprekinjenega pojava obdeluje zaporedje diskretnih vrednosti. Posamezna vrednost je *vzorec*, njihovo število v eni sekundi pa *frekvenca vzorčenja*.

V izvedenem sistemu je frekvenca vzorčenja 16 kHz, zato v eni sekundi nastane 16.000 vzorcev. Po Nyquistovem pravilu je mogoče brez zrcaljenja predstaviti frekvence do polovice frekvence vzorčenja, v tem primeru do 8 kHz. To zadošča uporabljeni predobdelavi, ki upošteva območje od 125 Hz do 7,5 kHz. Višja frekvenca vzorčenja bi ohranila več visokofrekvenčne vsebine, vendar bi povečala količino podatkov in računsko zahtevnost.

Amplituda vzorca opisuje odmik signala od njegove srednje vrednosti. Sistem uporablja predznačene šestnajstbitne vzorce, katerih dovoljeno celoštevilsko območje je od -32.768 do 32.767 . Večja absolutna vrednost praviloma pomeni močnejši trenutni signal, vendar sama amplituda še ne pove, za kateri zvok gre. Pasji lajež in plosk sta na primer lahko podobno glasna, razlikujeta pa se po trajanju in porazdelitvi energije po frekvencah. Zajema se en kanal, zato vsak časovni trenutek predstavlja ena sama vrednost in ne par levega ter desnega kanala.

Na razvojni plošči je digitalni mikroelektromehanski mikrofoni. Njegov neposredni izhod ni šestnajstbitna amplituda, temveč hiter enobitni pulznogostotni tok. Gostejše zaporedje enic oziroma ničel predstavlja odmik zvočnega signala v eno ali drugo smer. Digitalni filter zato tok najprej nizkoprepustno filtrira in zmanjša njegovo časovno ločljivost. Rezultat so običajni večbitni zvočni vzorci, ki jih lahko uporablja nadaljnja predobdelava. Natančna nastavitve mikrofona, filtra in prenosa v pomnilnik je opisana v poglavju 4.

2.2 Časovno-frekvenčna predstavitev

Surova zvočna oblika pokaže spreminjanje amplitude, ne pa tudi, katere frekvence so prisotne v posameznem trenutku. Prav te razlike pomagajo ločiti zvoke: sirena ima navadno trajnejše ozke frekvenčne komponente, razbitje stekla kratek širokopasoven prehod, govor pa zapleteno časovno zaporedje. Pred modelom se zato signal pretvori v logaritemski melov spektrogram. Ta z barvo oziroma številčno vrednostjo prikaže energijo posameznega frekvenčnega pasu v določenem trenutku, zato hkrati ohrani podatke o času in frekvenci.

2.2.1 Kratkočasovna Fourierjeva transformacija

Fourierjeva transformacija pokaže, katere frekvence sestavljajo signal in kako izrazita je vsaka od njih. Če bi jo izračunali za celoten posnetek, bi dobili njegovo skupno frekvenčno vsebino, ne pa tudi podatka, kdaj se je posamezna

frekvenca pojavila. Pri kratkočasovni Fourierjevi transformaciji se zato signal razdeli na kratka, delno prekrivajoča se okna. Transformacija se izračuna za vsako okno posebej.

Za časovno okno z zaporedno številko m in frekvenčno mesto k je izračun zapisljiv kot

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] w[n] e^{-j2\pi kn/N_F}, \quad (2.1)$$

kjer je x vhodni signal, w utežna okenska funkcija, N število dejanskih vzorcev v oknu, H korak med začetkoma dveh oken in N_F velikost Fourierjeve transformacije. Kompleksni rezultat $X(m, k)$ vsebuje velikost in fazo posamezne frekvenčne sestavine. Za uporabljeni spektrogram je pomembna predvsem velikost.

V sistemu ima okno 400 vzorcev oziroma 25 ms, korak pa 160 vzorcev oziroma 10 ms. Sosednji okni se zato prekrivata v 240 vzorcih oziroma 15 ms. Prekrivanje zmanjša možnost, da bi kratek dogodek padel ravno na neugodno mejo med oknom. Pred transformacijo se uporabi Hannova okenska funkcija, ki ublaži umetni frekvenčni preskok na robovih okna. Izračun je velikosti 512; manjkajočih 112 mest se dopolni z ničlami. Takšna dopolnitev ne ustvari novih informacij, omogoči pa učinkovito izvajanje hitre Fourierjeve transformacije in določi gostejšo mrežo frekvenčnih mest.

En vhod modela vsebuje 96 zaporednih časovnih oken. Prvo okno potrebuje 400 vzorcev, vsako naslednje pa se začne 160 vzorcev pozneje. Celoten potreben odsek zato vsebuje

$$400 + (96 - 1) \cdot 160 = 15.600 \quad (2.2)$$

vzorcev oziroma 975 ms zvoka. Dokumentacija modela časovno dolžino navadno podaja kot $96 \cdot 10 \text{ ms} = 960 \text{ ms}$, torej kot število oken, pomnoženo z njihovim korakom. Dejanska izvedba mora upoštevati še trajanje prvega okna, zato za izračun vseh 96 oken potrebuje 15.600 vzorcev. Nova odločitev se v končni aplikaciji izračuna vsakih 480 ms, saj si zaporedna vhoda delita približno polovico zvočnega gradiva.

2.2.2 Melova lestvica in logaritemski spektrogram

Frekvenčna mesta Fourierjeve transformacije so enakomerno razporejena v hercih. Človeško zaznavanje višine pa ni linearno: pri nizkih frekvencah so majhne razlike zaznavnejše kot pri visokih. Melova lestvica frekvenco približno preslika v zaznavno primernejšo razdaljo. Ena izmed običajnih preslikav je

$$M(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right), \quad (2.3)$$

kjer je f frekvenca v hercih, $M(f)$ pa položaj na melovi lestvici.

Na spekter vsakega časovnega okna se uporabi 64 delno prekrivajočih se trikotnih filtrov. Vsak filter sešteje energijo bližnjih frekvenčnih mest v en melov pas. S tem se več sto frekvenčnih vrednosti skrči v 64 vrednosti, pri čemer se ohrani za razpoznavanje pomembna oblika spektra. Na koncu se uporabi logaritem. Ta zmanjša razpon med zelo tihimi in zelo močnimi komponentami ter omogoči, da model poleg najmočnejših vidi tudi šibkejše, vendar značilne dele zvoka.

Rezultat predobdelave je logaritemski melov spektrogram velikosti 96×64 : 96 časovnih korakov opisuje spreminjanje zvoka, 64 melovih pasov pa njegovo frekvenčno vsebino. Vhodni tenzor končnega modela ima obliko $1 \times 1 \times 96 \times 64$; prvi enici označujeta en primer in en vhodni kanal. Posamezna vrednost spektrograma torej ni zvočni vzorec, temveč mera energije v določenem frekvenčnem pasu in časovnem oknu. Enake parametre uporablja uradna različica YAMNet-1024 za STM32N6 [15].

2.3 Razvrščanje zvočnih dogodkov

Model vsakemu vhodnemu spektrogramu priredi oceno za vse naučene razrede. Med učenjem pozna pravilno oznako in svoje uteži prilagaja tako, da ji dodeli čim višjo oceno. Pri uporabi vrne vektor ocen za nov spektrogram. Najvišja ocena je trenutna najverjetnejša razlaga zvoka, ni pa nujno že dovolj

zanesljiva za opozorilo.

Tudi kadar so izhodi normalizirani in je njihova vsota ena, vrednosti niso samodejno umerjene verjetnosti pravilnosti. Ocena 0,90 pomeni, da model močno daje prednost določenemu razredu glede na druge naučene razrede. Ne pomeni pa, da bo napoved pravilna v natanko 90 odstotkih enakih primerov. Zato so v nalogi vrednosti poimenovane *ocene modela*; pravilnost sistema se meri ločeno na preizkusnih posnetkih.

Resnični zvočni svet je odprta množica. Model se lahko uči na omejenem številu razredov, med uporabo pa prejme glasbo, trkanje, premikanje predmetov ali drug zvok, ki ga v ciljnem naboru ni. Če ima model samo nevarnostne izhode, mora tudi takemu vhodu dodeliti enega izmed njih. Razreda govor in drugo zato delujeta kot varovalna razreda. Govor pokriva zelo pogost nenevaren zvok, razred drugo pa raznolike preostale primere. Razred drugo kljub temu ne more predstavljati vseh mogočih neznanih zvokov; njegova učinkovitost je odvisna od raznolikosti učnih podatkov.

Posamezna napoved še ni končna odločitev naprave, saj se ocene med prekrivajočimi se odseki spreminjajo. Odločitvena plast uporablja glajenje, razredne pragove in več zaporednih potrditev. Če noben razred ne izpolni svojih pogojev, sistem zvok označi kot neznan. Višji prag zmanjša lažne alarme, a lahko spregleda več dogodkov; nižji naredi obratno. Zato je treba vrednotiti celotno pot od zajema do časovnega odločanja, ne le nevronske mreže na datotekah.

2.4 YAMNet, prenos učenja in kvantizacija

2.4.1 Prednaučeno ogrodje YAMNet

AudioSet je obsežna hierarhično označena zbirka zvočnih dogodkov, zbranih iz spletnih videoposnetkov [3]. Na njej je bil naučen model YAMNet, ki splošni vhodni zvok razvršča med 521 oznak [4, 20]. Takšen model že pozna splošne vzorce govora, živali, glasbe, strojev in drugih okoljskih zvokov. Njegova izhodna plast pa je naučena razlikovati vseh 521 oznak zbirke AudioSet.

Številne med njimi za naš sistem niso pomembne, posamezna ciljna nevarnost pa je lahko razdeljena med več sorodnih oznak. Zato izhod modela ni neposredno prilagojen izbranemu naboru nevarnosti in varovalnemu razredu drugo.

YAMNet temelji na arhitekturi MobileNetV1 [5]. Njena ključna lastnost so globinsko ločljive konvolucije. Običajna konvolucija v enem koraku išče prostorske vzorce in hkrati povezuje vse vhodne kanale. Globinsko ločljiva konvolucija nalogo razdeli na dva dela: najprej uporabi svoj filter za vsak kanal posebej, nato pa z enotočkovno konvolucijo velikosti 1×1 poveže rezultate med kanali. Tak razcep praviloma potrebuje manj parametrov in operacij, zato je primeren za mobilne in vgrajene naprave.

V nalogi je uporabljena različica YAMNet-1024 iz zbirke modelov podjetja STMicroelectronics. Od izvirnega modela ohrani prednaučeno konvolucijsko ogrodje, predobdelava zvočnega signala pa je izvedena v programu mikrokromilnika. Izhod ogrodja je vektor 1024 značilk. Vsaka vrednost v njem sama po sebi nima oznake, kot je »sirena« ali »strel«; celoten vektor je zgoščen opis vzorcev, ki jih je ogrodje prepoznalo v spektrogramu. Število 1024 zato označuje dolžino opisa in ne števila zvočnih razredov [15].

2.4.2 Prenos učenja

Učenje celotnega omrežja od začetka bi zahtevalo precej več označenih posnetkov, časa in računske zmogljivosti. Pri prenosu učenja se ohrani znanje prednaučenega modela, ciljni nalogi pa se prilagodi njegov zaključek. Uteži ogrodja YAMNet-1024 so zato ostale zamrznjene. Nova polno povezana plast 1024 značilk pretvori v sedem ocen: pasji lajež, razbitje stekla, strel oziroma streljanje, nevihto, sireno, govor in drugo.

Zaključna plast ima za vsak izhod 1024 uteži in eno pristranskost, skupaj $1024 \cdot 7 + 7 = 7175$ učljivih parametrov. Prednaučeni del prispeva večino od skupno 3.224.519 parametrov, vendar se njegove uteži med učenjem ciljne naloge ne spreminjajo. Tako lahko omejen namenski nabor podatkov nauči novo povezavo med splošnimi zvočnimi značilkami in izbranimi razredi, ne da

bi moral ponovno odkriti osnovne spektralne vzorce. Podrobnosti podatkov, povečav in poteka učenja so podane v poglavju 4.

Končna programska oprema sedem modelskih ocen pretvori v šest uporabniških razredov. Ker nevihta po končni opredelitvi namena ni samostojno opozorilo, se njena ocena prišteje razredu drugo. To omogoča ohranitev že naučenega modela, uporabniku pa se ne prikazuje dogodek, ki ni del izbranega nabora nevarnosti.

2.4.3 Osemitna celoštevilaska kvantizacija

Model se med učenjem praviloma računa z 32-bitnimi števili s plavajočo vejico. Na mikrokrmilniku tak zapis poveča velikost uteži in ni najprimernejši za namenski nevronske pospeševalnik. Pri kvantizaciji se realna vrednost r približno preslika v osemitno celo število q z zvezo

$$q = \text{clip}\left(\text{round}\left(\frac{r}{s}\right) + z\right), \quad (2.4)$$

kjer je s pozitivni kvantizacijski korak, z pa ničelna točka. Funkcija clip rezultat omeji na dovoljeno osemitno območje. Korak določa, kolikšen razpon realnih vrednosti predstavlja ena celoštevilaska stopnja, ničelna točka pa poskrbi, da je mogoče natančno predstaviti realno ničlo. Pri povratni pretvorbi velja približek $r \approx s(q - z)$.

Ker ima osemitna utež štirikrat manjši zapis od 32-bitne uteži, se bistveno zmanjša pomnilniški odtis uteži. Celoštevilske operacije so tudi oblika, za katero je načrtovan uporabljeni pospeševalnik. Kvantizacija pa zaokroža vrednosti in lahko zmanjša kakovost modela. Reprezentativni kalibracijski primeri zato določijo primerne razpone vmesnih vrednosti. Razmerje med natančnostjo, hitrostjo in velikostjo je treba preveriti z meritvami, ne zgolj predpostaviti [6].

2.5 Robna umetna inteligenca in nevronske pospeševalniki

Robna naprava podatke obdela blizu njihovega izvora. V našem sistemu so mikrofoni, predobdelava, nevronske sklepanje in zaslon na isti razvojni plošči, zato običajno delovanje ne potrebuje omrežja ali oddaljene storitve. Surovi zvok se ne pošilja v računalniški oblak in se ne hrani trajno. Zasebnost pa s tem še ni samodejno rešena: pomembni ostajajo fizična zaščita naprave, diagnostični vmesniki ter ravnanje z učnimi in preizkusnimi posnetki.

Splošno procesorsko jedro je prilagodljivo in primerno za krmiljenje periferije, izračun spektrograma, odločanje ter uporabniški vmesnik. Izvajanje več milijonov ponavljajočih se konvolucijskih operacij samo na njem pa ni nujno najučinkovitejša uporaba strojne opreme. Nevronske pospeševalnike Neural-ART v mikrokontrolerju STM32N6 je namenjen vzporednemu izvajanju takšnih operacij. Orodje ST Edge AI model predhodno prevede, razporedi podprte operacije in pripravi statična pomnilniška območja za uteži ter vmesne aktivacije [16, 18].

Pospeševalnik ni samostojen program. Procesorsko jedro še vedno zajame zvok, pripravi vhodni tenzor, sproži izvajanje omrežja in obdela izhod. Prav tako mora prevajalnik upoštevati, katere operacije podpira strojna enota in kje so shranjeni podatki. Če del modela ni podprt ali če prenos med pomnilniškimi območji predstavlja ozko grlo, se pričakovana pohitritev zmanjša. Zato število operacij modela samo po sebi ne določa časa izvajanja.

Za sprotno delovanje mora biti celotna obdelava končana pred prihodom naslednjega odseka, ki zahteva novo odločitev. V končni izvedbi je ta razmik 480 ms. Čas predobdelave in sklepanja je zato izmerjen na fizični napravi v poglavju 6. Poraba električne energije ni bila merjena, zato iz uporabe pospeševalnika ne izpeljemo številčne trditve o energijskem prihranku.

2.6 Sorodna dela

Izbrana sorodna dela pokrivajo šest za nalogo pomembnih primerov: splošni prednaučeni model, uradno izvedbeno izhodišče, dva majhna modela za naprave z omejenimi viri in dva pomožna sistema za gluhe in naglušne osebe. Ne gre za izčrpen pregled razpoznavanja zvoka, temveč za primerjavo prenosa učenja, izvedbe na mikrokrmilniku, pomnilniških omejitev, sprotnega sklepanja, zasebnosti in prikaza uporabniku.

2.6.1 Prednaučeni model in izvedbeno izhodišče

Splošni YAMNet predstavlja izhodišče za prenos učenja v tej nalogi. Google ga je zasnoval kot splošni razpoznavalnik 521 zvočnih dogodkov iz zbirke AudioSet. Vhodni signal razdeli na kratke odseke in jih pretvori v logaritemske melove spektrograme, ogrodje MobileNetV1 pa ustvari 1024 značilk [20]. Tak pristop zagotovi široko prednaučeno znanje, ne rešuje pa sam po sebi izbire ciljnih nevarnosti, zavračanja zvokov zunaj ciljnega nabora, izvajanja na konkretni plošči in prikaza uporabniku.

Najbližje tehnično izhodišče je uradni paket podjetja STMicroelectronics za razpoznavanje zvočnih dogodkov na STM32N6570-DK. Vsebuje izvedbo brez operacijskega sistema in različice z operacijskim sistemom za delo v stvarnem času, 64 melovih pasov, 96 časovnih oken ter kvantizirani YAMNet-1024 z desetimi razredi iz zbirke ESC-10 [17]. Paket pokaže celotno osnovno pot od mikrofona do izpisa rezultata in je zato predstavljal začetno izvedbeno osnovo. Ne obravnava pa namenskega nabora nevarnosti, lastnega podatkovnega postopka, grafičnega vmesnika in neodvisnega fizičnega vrednotenja, ki so predmet te naloge.

2.6.2 Drugi modeli za naprave z omejenimi viri

Mohaimenuzzaman in sodelavci so razvili model Micro-ACDNet in postopek, s katerim so večje konvolucijsko omrežje za razpoznavanje surovega zvoka stisnili in kvantizirali [10]. Njihova različica za 50 razredov ima približno

131.000 parametrov in je bila izvedena na mikrokrmilniški plošči Sony Spre-sense. Študija poudari omejitve delovnega pomnilnika in pokaže, da lahko kvantizacija opazno spremeni pravilnost. V primerjavi s sistemom za zaznavanje nevarnih zvokov na plošči STM32N6, razvitim v tej diplomski nalogi, je njihov model manjši in neposredno obdeluje časovno obliko zvočnega signala. Cilj študije je splošen postopek stiskanja modela, ne namenski sistem vidnega opozarjanja.

Elliott in sodelavci so raziskali majhne transformatorske modele za razpoznavanje okoljskih zvokov [1]. Najmanjši model za šest pisarniških razredov ima 6.642 parametrov in je pri preverjanju na telefonu Samsung Galaxy S9 sklepanje opravil v približno 7 ms. Avtorji so velikost izbrali z mislijo na pomnilnik mikrokrmilniške plošče Arduino Nano 33 BLE Sense, vendar fizične izvedbe na tej plošči niso predstavili. Delo pokaže, da velikost modela ni edina pot do dobrega rezultata: pri ozkem problemu lahko zelo majhen model tekmuje z večjim konvolucijskim modelom. Rezultati sicer niso neposredno primerljivi s to nalogo, saj se razlikujejo razredi, dolžina vhoda, strojna platforma in preizkusni podatki.

2.6.3 Pomožni sistemi za gluhe in naglušne osebe

Jain in sodelavci so razvili domači sistem HomeSound, sestavljen iz več zaslonov z mikrofoni in pozneje tudi pametne ure. Prva različica je prikazovala glasnost, višino, trajanje in prostor izvora zvoka, druga pa je dodala samodejno razvrščanje 19 gospodinjskih zvokov. Obe različici so po tri tedne preizkušali v domovih gluhih in naglušnih oseb; skupaj je sodelovalo šest različnih gospodinjstev [7]. Sistem je povečal zavedanje o dogajanju v domu, vendar so uporabnike motile napačne razvrstitve in prepogoste vibracije pametne ure. Pojavila so se tudi vprašanja zasebnosti obiskovalcev. Delo je za to nalogo pomembno, ker pokaže, da visoka laboratorijska pravilnost sama ne zagotavlja uporabnega opozorilnega sistema. Naša rešitev zato uporablja časovno potrjevanje in razredne pragove, vendar uporabniška študija z gluhih in naglušnih osebami ni bila izvedena.

Lin in sodelavci so predstavili dvostopenjski notranji sistem za prikaz zvokov gluhih in naglušnim osebam [9]. Manjši model Dynamic MobileNet na računalniku Raspberry Pi najprej razvrsti zvok in oceni negotovost. Če je ocena premalo zanesljiva, se posnetek pošlje strežniku, kjer ga obdelava večji model YAMNet. Rezultat se prikaže na pametnem telefonu ali uri. Sistem je na preizkusnem naboru, sestavljenem iz zbirk ESC-50 in ReaLISED, dosegel 90-odstotno pravilnost za 14 pomembnih razredov; za 86 širših skupin iz zbirke AudioSet je dosegel 74 odstotkov. Rezultatov zaradi drugačnih razredov in preizkusnih podatkov ni mogoče neposredno primerjati z rezultati te naloge. Arhitekturna razlika pa je jasna: dvostopenjski pristop s strežnikom omogoča uporabo večjega modela ob negotovih primerih, medtem ko naša naprava celotno obdelavo izvede lokalno in zvoka ne pošilja v omrežje.

2.6.4 Primerjava in umestitev naloge

Glavne razlike med pristopi povzema tabela 2.1.

Vrzel, ki jo naslavlja naloga, zato ni nov splošni model za razpoznavanje zvoka. Prispevek je celovita prilagoditev prednaučenega modela in razvoj fizičnega sistema za izbrane nevarne dogodke: neposredni zajem z vgrajenim mikrofonom, enaka predobdelava pri učenju in na napravi, namenski učni razredi, lokalno sklepanje, časovno stabilizirana odločitev, vidno opozorilo ter meritev na končni strojni opremi. Sistem je zasnovan kot prototip pomoči gluhih in naglušnim osebam, pri čemer običajno delovanje ne potrebuje računalniškega oblaka in ne hrani surovega zvoka.

Tabela 2.1: Primerjava izbranih pristopov s sistemom, razvitim v diplomski nalogi.

Pristop in platforma	Glavne značilnosti in primerjava
Google YAMNet Splošne računalniške platforme	MobileNetV1 obdela logaritemski melov spektrogram in vrne 521 oznak. Model je splošna prednaučena osnova, ne namenski sistem opozarjanja.
Začetni zvočni paket ST STM32N6570-DK in Neural-ART	YAMNet-1024 uporablja vhod 96×64 in deset razredov ESC-10. Paket je bil strojno izhodišče ter primer namestitve modela.
Micro-ACDNet Sony Spresense	Model neposredno obdela 1,5 s zvočnega signala in razlikuje 50 razredov. Poudarek je na stiskanju, kvantizaciji in pomnilniku.
Majhen transformator Samsung Galaxy S9	Melov spektrogram razvršča med šest pisarniških zvokov. Model je zelo majhen, fizična izvedba na mikrokrmilniku pa ni prikazana.
HomeSound Domači zasloni in pametna ura	Sistem prepozna 19 gospodinjskih zvokov. Terenski preizkus obravnava uporabnost, zasebnost in težavo prepogostih opozoril.
Dvostopenjski sistem Raspberry Pi in strežnik	Dynamic MobileNet deluje lokalno, negotovi primeri pa se pošljejo modelu YAMNet na strežniku. Nabor zvokov je širši, vendar zvok zapusti napravo.
Sistem iz diplomske naloge STM32N6570-DK in Neural-ART	Model YAMNet-1024 uporablja vhod 96×64 in sedem izhodov, odločitveni del pa jih združi v šest sistemskih razredov. Celoten fizični sistem deluje lokalno; ovrednoteni so zaznave, lažni alarmi, čas izvajanja in pomnilniški odtis.

Poglavje 3

Zasnova sistema

Zasnova poveže zvok v prostoru z opozorilom na zaslonu. Izhaja iz preverljivih zahtev, nato določi strojno platformo, razdelitev nalog, tok podatkov in pravila za prikaz rezultata. Programske podrobnosti sledijo v Poglavju 4.

3.1 Funkcionalne in nefunkcionalne zahteve

Izhodišče je samostojna namizna naprava, ki zvočno dogajanje pretvori v vidno opozorilo za gluho ali naglušno osebo. Za osnovno delovanje ne sme potrebovati telefona, osebnega računalnika ali interneta. Zahteve so zbrane v tabeli 3.1.

Zahteve se preverijo z uporabniškim vmesnikom, meritvami časa in pregledom zagonskih datotek. Omejitev 480 ms izhaja iz razmika med začetkoma dveh zaporednih vhodov modela. Posamezna obdelava ga ne sme preseči; izmerjeni časi so podani v poglavju 6.

Zahtevi glede zasebnosti in sledljivosti sta posebej pomembni za predvideno neprekinjeno poslušanje. Zvočni vzorci ostanejo v začasnih medpomnilnikih na napravi in se po obdelavi prepisejo. Poseben diagnostični način za zajem zvoka je bil uporabljen samo med razvojem in ni vključen v običajni zagon končnega izdelka. Različici aplikacije in uteži sta določeni z razvojnimi zapisi ter kontrolnimi vsotami, zato je mogoče ponoviti uporabljeno izvedbo.

Tabela 3.1: Glavne zahteve sistema.

Vrsta	Zahteva
Funkcionalna	Neprekinjen zajem zvoka z vgrajenega mikrofona.
Funkcionalna	Prikaz pasjega laježa, razbitja stekla, strela, sirene, govora in razreda drugo.
Funkcionalna	Ločeni stanji za nezanesljivo napoved in neaktiven vhod.
Funkcionalna	Prikaz treh najvišjih ocen in zgodovine potrjenih dogodkov.
Nefunkcionalna	Zaključek obdelave pred naslednjim odločitvenim korakom, ki nastopi vsakih 480 ms, brez izgube zvočnih vzorcev.
Nefunkcionalna	Delovanje brez omrežne povezave in računalniškega oblaka.
Nefunkcionalna	Brez trajnega shranjevanja surovega zvoka v običajnem načinu.
Nefunkcionalna	Ponovljiv zagon podpisane aplikacije ter sledljiva različica modela in uteži.

3.2 Strojna platforma STM32N6570-DK

Razvojna plošča STM32N6570-DK na eni napravi združi zajem zvoka, izvajanje nevronske mreže in lokalni prikaz. Vsebuje mikrokrmilnik STM32N657 z jedrom Arm Cortex-M55, namenski nevronski pospeševalnik Neural-ART in 4,2 MiB notranjega statičnega pomnilnika z naključnim dostopom. Na plošči so še digitalni mikrofonski IMP34DT05, zunanji bliskovni pomnilnik velikosti 1 Gibit, zunanji pomnilnik z naključnim dostopom velikosti 256 Mibit in petpalčni zaslon ločljivosti 800×480 slikovnih točk [14]. Prototip zato za osnovno delovanje ne potrebuje zunanjega mikrofona, grafičnega krmilnika ali dodatnega računalnika.


V nadaljevanju oznaka STM32N6 pomeni družino mikrokrmilnikov, STM32N657 uporabljeni mikrokrmilnik, STM32N6570-DK pa celotno razvojno ploščo. Razvojna plošča je prikazana na sliki 3.1.

Procesorsko jedro vodi zajem, pripravo značilke, odločitveni filter in uporabniški vmesnik. Neural-ART izvaja računsko najzahtevnejše plasti nevronske mreže, zunanji bliskovni pomnilnik hrani podpisano aplikacijo in uteži, HyperRAM pa dva zaslonska medpomnilnika. Takšna razdelitev omogoča sočasno zajemanje zvoka in obdelavo prejšnjega bloka ter prepreči, da bi prikaz porabil notranji pomnilnik, potreben za program in začasne rezultate modela.


3.3 Arhitektura podatkovnega toka

Slika 3.2 prikazuje podatkovni tok. Vsak blok ima svojo nalogo, podatki pa med običajnim delovanjem ne zapustijo naprave.

Digitalni mikrofonski oddaja pulzno-gostotni tok, ki ga strojni filter pretvori v zvočne vzorce s frekvenco 16 kHz. Neposredni dostop do pomnilnika jih zapisuje brez posredovanja procesorskega jedra pri vsakem vzorcu. Predobdelava iz skoraj ene sekunde zvoka pripravi 64-pasovni logaritemski melov spektrogram. Ta se kvantizira in neposredno zapiše v vhodni pomnilnik omrežja. Sedem ocen modela se nato pretvori v šest uporabniških razredov,



Slika 3.1: Pogled na stran z elektronskimi sestavnimi deli razvojne plošče STM32N6570-DK. Vidni so mikrokrmilnik, pomnilniki in priključki, uporabljeni pri izvedbi sistema.



Slika 3.2: Poenostavljen tok podatkov od zvoka v prostoru do lokalnega vizualnega opozorila.

časovni filter pa preprečuje, da bi kratka nihanja takoj postala opozorilo.

Tabela 3.2 povzema razdelitev dela. Nevronski pospeševalnik ne prejema surovega zvoka, temveč pripravljen osembitni spektrogram. Po sklepanju procesorsko jedro dobi sedem številskih ocen in iz njih pripravi uporabniško odločitev.

Tabela 3.2: Razdelitev nalog in podatkov med deli sistema.

Del sistema	Naloga in rezultat
Mikrofon, digitalni filter in neposredni dostop do pomnilnika	zajem in strojna pretvorba signala v šestnajstbitne zvočne vzorce
Procesorsko jedro Cortex-M55	priprava značilk in kvantizacija v spektrogram velikosti 96×64
Nevronski pospeševalnik Neural-ART	izvajanje nevronske mreže in priprava sedmih ocen razredov
Procesorsko jedro in krmilnik zaslona	časovno filtriranje ter prikaz stanja in opozorila za uporabnika

3.4 Programska zgradba in zagonski tok

Program izhaja iz referenčne zvočne aplikacije podjetja STMicroelectronics za mikrokrmilnik STM32N6 [17]. Ta je zagotovila začetno nastavitve ure, mikrofona, pomnilnikov in pospeševalnika. Dodani so bili ciljni model, odločitveni filter, diagnostični zapisi in lasten prikaz. Končna različica nima operacijskega sistema; glavna zanka obdela zvočni blok, ko se v krožnem medpomnilniku zbere dovolj vzorcev. Zajem se medtem nadaljuje z neposrednim dostopom do pomnilnika, zato jedru ni treba čakati na vsak vzorec posebej.

Po ponastavitvi začetni nalagalec preveri podpis aplikacije v zunanjem bliskovnem pomnilniku in jo prenese v notranji pomnilnik za izvajanje. Uteži

modela ostanejo v ločeni particiji zunanjega bliskovnega pomnilnika. Aplikacija nato inicializira zunanji pomnilnik, zaslon, zvočni zajem, predobdelavo in izvajalno okolje nevronske mreže. Takšna zgradba omogoča ločeno posodobitev aplikacije in uteži. Podpis zagotavlja preverjanje zagonske slike, kontrolni vsoti v razvojnem zapisu pa določata točno uporabljeni datoteki aplikacije in uteži.

3.5 Nabor razredov in politika odločanja

Nevronska mreža ima sedem učnih izhodov: pasji lajež, razbitje stekla, strel, drugo, sirena, govor in nevihta. Končni uporabniški vmesnik prikazuje šest razredov. Nevihta po končni odločitvi o namenu izdelka ni obravnavana kot samostojen nevarnostni dogodek; njena ocena se pred glajenjem prišteje razredu *drugo*. S tem se ohrani že naučeni model, uporabnik pa nevihte ne vidi kot posebnega opozorila.


Nevarnostni razredi so pasji lajež, razbitje stekla, strel in sirena. Govor in drugo sta informacijska oziroma varovalna razreda. Njuna naloga je poimenovati pogoste nenevarne vhode, ki bi sicer lahko tekmovali z nevarnostnimi razredi. Razred drugo vključuje raznolike zvoke, med njimi ploskanje, aplavz, zvonce, kratke poke, gospodinjske zvoke, veter in glasbo.

Najvišja surova ocena modela še ni končna odločitev. Ocene se gladijo skozi čas, vsak razred ima svoj prag in zahtevano število zaporednih potrditev. *Neznano* pomeni aktiven zvok brez dovolj zanesljivega izhoda, medtem ko *čakanje* pomeni, da vhod ni presegel energijskega praga. Neznano in čakanje zato nista dodatna razreda nevronske mreže. Podrobnosti odločitvenega filtra so opisane v poglavju 4.

3.6 Zasnova prikaza opozoril

Prikaz je zasnovan tako, da je najpomembnejša odločitev vidna brez branja manjših podrobnosti. Osrednje območje zato vsebuje trenutno stanje, ime

zvoka in njegovo oceno. Spodnji območji odgovorita na dve dodatni vprašanji: med katerimi razredi se model trenutno odloča in kateri dogodki so bili nedavno potrjeni. Glava prikazuje čas delovanja, spodnja vrstica pa zadržano opozorilo ter navodilo za njegovo potrditev. Razporeditev prikazuje slika 3.3.



Slika 3.3: Načrt razporeditve informacij na zaslonu.

Nevarnost ni označena samo z barvo. Na zaslonu se hkrati spremenijo ime dogodka, besedilno stanje in spodnje zadržano opozorilo, zato pomen ostane razumljiv tudi brez razlikovanja barv. Prikaz je bil izdelan za delujoči prototip, njegova uporabnost za gluhe in naglušne osebe pa v okviru naloge ni bila preverjena z uporabniško študijo.

Zasnova poveže tri časovne ravni: neprekinjen zajem vzorcev, periodično obdelavo prekrivajočih se blokov in potrjevanje opozorila skozi več zaporednih napovedi. Naslednje poglavje opisuje njihovo izvedbo in prilagoditev omejitvam plošče.

Poglavje 4

Implementacija

To poglavje sledi dejanski poti od zvoka v prostoru, do odločitve na zaslonu. Program deluje brez operacijskega sistema in omrežne povezave. Procesorsko jedro vodi zajem, predobdelavo, odločanje, zaslon in diagnostični izhod, računsko najzahtevnejše plasti modela pa izvede Neural-ART.

Za strojno izhodišče smo uporabili uradni zvočni primer za družino STM32N6 [17]. Vseboval je gonilnike mikrofona, izračun zvočnih značilk in povezavo z izvajalnim okoljem ST. Na tej osnovi smo zamenjali model, prilagodili predobdelavo ter dodali šestrazredno uporabniško odločanje, časovni filter, lasten vmesnik in strukturirane meritve. Tako napake v osnovni nastavitvi strojne opreme nismo zlahka zamenjali za napako modela.

Razvojna orodja in njihovo vlogo povzema tabela 4.1. Vgrajeni program je bil preveden in razhroščen v okolju STM32CubeIDE, model pa je bil pred namestitvijo obdelan z uradnimi orodji podjetja STMicroelectronics [15, 16].

4.1 Zajem in prenos zvočnih podatkov

Vgrajeni digitalni mikrofoni IMP34DT05 je na spodnjem delu plošče in oddaja pulzno-gostotni signal [14]. Ker to še niso običajni šestnajstbitni zvočni vzorci, ga je treba pred nadaljnjo obdelavo filtrirati in zmanjšati njegovo vzorčno hitrost.

Tabela 4.1: Glavna razvojna orodja in njihova vloga.

Orodje	Uporaba v projektu
STM32CubeIDE 2.2.0	Prevajanje, povezovanje in razhroščevanje vgrajenega programa v jezikih C in C++.
Python in razširitve zbirke modelov STM32	Priprava zvočnih podatkov, učenje zaključne plasti, povečanje podatkov ter izvoz modela.
ST Edge AI Core 4.0.1	Analiza kvantiziranega modela, razporeditev operacij med Neural-ART in procesorsko jedro ter priprava izvedbenih datotek.
STM32CubeProgrammer	Zapis podpisane aplikacije in uteži v zunanji bliskovni pomnilnik razvojne plošče.
PowerShell	Ponovljivo predvajanje dražljajev, zajem serijskega izhoda in vodenje fizičnih preizkusov.
Git	Sledenje različicam programske kode, modela in dokumentacije.

V končni izvedbi smo za ta korak uporabili prvi večnamenski digitalni filter mikrokrmilnika. Gonilnik plošče nastavi vir na digitalni mikrofoni, vzorčno frekvenco na 16 000 Hz, ločljivost na 16 bitov in število kanalov na enega. Večnamenski digitalni filter opravi strojno filtriranje ter iz pulzno-gostotnega toka pripravi 32-bitne vmesne vrednosti. Gonilnik vsako vrednost deli z 256, jo omeji na dovoljeno območje predznačenega šestnajstbitnega števila in jo shrani kot enokanalni zvočni vzorec. Pulzno-gostotni tok predstavlja amplitudo z gostoto enic in ničel, 32-bitni vmesni zapis pa ohrani natančnost rezultata filtriranja. Deljenje prilagodi merilo šestnajstbitnemu zapisu, omejitev pa prepreči številski preliv.

Prenos iz periferne enote v pomnilnik poteka z neposrednim dostopom do pomnilnika. Prenosna enota deluje v krožnem načinu, zato procesorskemu jedru ni treba prebrati vsakega vzorca posebej. Zajemni medpomnilnik vsebuje 320 vzorcev, kar pri 16 000 Hz pomeni 20 ms zvoka. Prenosna enota sproži povratni klic po zapolnitvi prve in druge polovice medpomnilnika. Posamezen povratni klic tako preda 160 vzorcev oziroma 10 ms zvoka.

V prvih 10 ms se na primer zapolnijo mesta od 0 do 159 in sproži se prvi povratni klic. Med njegovim izvajanjem prenosna enota že polni mesta od 160 do 319. Po drugem povratnem klicu se vrne na mesto 0, zato zajema ni treba ustaviti.

Povratni klici morajo biti kratki, saj se izvajajo med neprekinjenim zajemom. Njihova naloga je le kopiranje nove polovice medpomnilnika v večji krožni medpomnilnik aplikacije. Ta hrani položaj naslednjega zapisa, položaj naslednjega branja in število razpoložljivih vzorcev. Pri doseženem koncu pomnilniškega območja se položaj vrne na začetek. Med spremembo skupnih kazalcev so prekinitve za kratek čas onemogočene, s čimer se prepreči, da bi povratni klic spremenil stanje med branjem glavne zanke.

Glavna zanka v končni izvedbi čaka na 7.680 novih vzorcev, kar ustreza 480 ms zvoka. Iz prejšnjega bloka ohrani 7.920 vzorcev in jim pripne nove. Predobdelava zato ob vsakem zagonu prejme 15.600 vzorcev oziroma 975 ms signala, dve zaporedni omrežni obdelavi pa si delita približno polovico vho-

dnega zvoka. Tak prekrivajoči se korak zmanjša odvisnost kratkega dogodka od meje skoraj enosekundnega bloka.

Dolžina celotnega vhoda izhaja iz 96 časovnih oken. Prvo vsebuje 400 vzorcev, preostalih 95 pa se začne v razmiku po 160 vzorcev,

$$400 + 95 \cdot 160 = 15\,600. \quad (4.1)$$

Ker je razmik med okni manjši od njihove dolžine, si sosednji časovni okni delita $400 - 160 = 240$ vzorcev. To prekrivanje znotraj spektrograma ni enako prekrivanju dveh zaporednih omrežnih vhodov: slednje nastane zato, ker program pred vsakim novim izračunom premakne ohranjeni del prejšnjega 15.600-vzorčnega bloka in doda samo 7.680 novih vzorcev.

Zajem in obdelava sta s tem razvezana. Periferna enota ves čas sprejema zvok, glavna zanka pa obdeluje le dovolj velike bloke. Če bi predobdelava neposredno brala iz majhnega zajemnega medpomnilnika, bi ga lahko strojni prenos prepisal, še preden bi bila obdelava končana. Krožni medpomnilnik prepreči takšno tekmovanje za podatke in omogoča neprekinjeno delovanje brez operacijskega sistema.

4.2 Predobdelava zvočnega signala

Model ne prejme surovih vzorcev, temveč logaritemski melov spektrogram. Njegovi parametri morajo biti enaki kot pri učenju. Že druga vzorčna frekvenca ali razporeditev melovih filtrov bi spremenila vhodno porazdelitev in poslabšala napovedi.

Za vsak vhodni blok izvedemo naslednje korake. Signal razdelimo na 96 oken po 400 vzorcev. Dolžina posameznega okna je 25 ms, začetek naslednjega okna pa je zamaknjen za 160 vzorcev oziroma 10 ms. Vsako okno pomnožimo s Hannovo okensko funkcijo in ga simetrično dopolnimo z ničlami na 512 vzorcev; na vsaki strani dodamo 56 ničel. Nato z realno Fourierjevo transformacijo izračunamo magnitudni spekter.

Frekvenčne koše preslikamo v 64 melovih pasov med 125 Hz in 7500 Hz.

Uporabljena je melova preslikava po formuli, ki jo uporablja orodje Hidden Markov Model Toolkit. Nad energijami melovih pasov uporabimo naravni logaritem. Rezultat enega zvočnega bloka je matrika s 64 frekvenčnimi pasovi in 96 časovnimi stolpci. To je tudi vhodna predstavitev, predpisana za družino modelov YAMNet [20].

Tabela 4.2 vsebuje vrednosti iz konfiguracije končne izdaje programa, ne le načrtovanih nastavitev.

Tabela 4.2: Parametri predobdelave zvočnega signala.

Parameter	Vrednost
Vzorčna frekvenca	16 000 Hz, en kanal
Dolžina časovnega okna	400 vzorcev oziroma 25 ms
Razmik med okni	160 vzorcev oziroma 10 ms
Dolžina Fourierjeve transformacije	512 vzorcev
Število časovnih stolpcev	96
Število melovih pasov	64
Frekvenčno območje	od 125 Hz do 7500 Hz
Vrsta spektra	magnitudni spekter
Frekvenčna preslikava	melova preslikava po formuli orodja Hidden Markov Model Toolkit
Logaritemska preslikava	naravni logaritem
Oblika vhodnega tenzorja	en primer, en kanal, 96 časovnih korakov, 64 melovih pasov
Vrsta vhodnih elementov	predznačena osembitna cela števila

Matrika se že med izračunom pretvori v obliko, ki jo pričakuje model. Vsak realni element x delimo s kvantizacijskim korakom, rezultat zaokro-

žimo na najbližje celo število, mu prištejemo ničelno točko in ga omejimo na območje predznačenega osembitnega števila:

$$q = \max\left(-128, \min\left(127, \left\lfloor \frac{x}{0,034300160} \right\rfloor + 51\right)\right). \quad (4.2)$$

Kvantizacijski korak 0,034300160 pove, kolikšni spremembi realne vrednosti ustreza premik za eno celoštevilsko stopnjo. Ničelna točka 51 pomeni, da je realna vrednost 0 v osembitnem zapisu predstavljena s številom 51, zato se to število po deljenju prišteje rezultatu. Obe vrednosti sta pridobljeni neposredno iz prevedenega modela ob inicializaciji, zato v kodi predobdelave nista podvojeni kot ročno vpisani konstanti. Končni model uporablja vrstni red [1, 1, 96, 64]. Vseh 64 melovih vrednosti enega časovnega koraka je zato v pomnilniku zapisanih zaporedno, nato sledijo vrednosti naslednjega časovnega koraka. Ta razporeditev se razlikuje od zgodnejše različice modela in jo je bilo treba uskladiti tudi v vgrajeni predobdelavi. Po zapisu se območje podatkovnega predpomnilnika očisti in razveljavi. Tako nevronske pospeševalnik vidi najnovejše podatke in ne stare kopije, ki bi še ostala v predpomnilniku procesorskega jedra.

Predobdelava hkrati izračuna vsoto vrednosti spektrograma. Če vsota ne preseže praga 2800, se blok obravnava kot neaktiven. Model se sicer izvede tudi za tak blok, vendar odločitveni filter rezultata ne sme potrditi kot dogodek. Prag s tem deluje kot preprost vhodni nadzor aktivnosti in preprečuje, da bi tišina neprestano ustvarjala razred z največjo, vendar vseeno nezanesljivo oceno.

4.3 Priprava in pretvorba modela

Izvirni YAMNet uporablja arhitekturo MobileNetV1 in vrača ocene za 521 dogodkov iz zbirke AudioSet [19, 4, 3]. MobileNetV1 z globinsko ločljivimi konvolucijami zmanjšuje število parametrov in operacij ter je primeren za računsko omejene naprave [5]. Splošni izhod YAMNet pa ni prilagojen našemu naboru nevarnosti.

Končna izvedba uporablja YAMNet-1024 kot prednaučeni izločevalnik značilk. Število 1024 pomeni dolžino opisa vhodnega zvoka, ne števila razredov. Nova zaključna plast ga pretvori v sedem ocen. Model je večji od najprej preizkušenega YAMNet-256, vendar ga Neural-ART še vedno lahko izvede v realnem času.

Končni model ima sedem izhodov: pasji lajež, razbitje stekla, strel oziroma streljanje, drugo, sireno, govor in nevihto. Govor in razred drugo sta varovalna razreda. Govor je bil dodan, ker se je v zgodnjih preizkusih pokazalo, da lahko glasen človeški glas tekmuje z nevarnostnimi razredi. Razred drugo pa uči model, da ploskanja, aplavza, kratkih pokov, kovinskih zvokov, glasbe, vremenskega ozadja in gospodinjskih zvokov ne prisili v eno od nevarnostnih oznak. V končni programski opremi se ocena nevihte prišteje razredu drugo, zato uporabnik vidi šest sistemskih razredov in štiri vrste nevarnosti.

4.3.1 Učni podatki in povečanje učnega nabora

Učnih podatkov nismo dobili le s prepisom oznak iz javnih zbirk. Metapodatki so dali začetni seznam kandidatov, problematične razrede pa smo poslušali in po ugotovljenih napakah popravljali pravila izbire. Evidenca za vsak vir hrani njegovo vlogo, zbirko in njen del, identifikator, prvotno ime ter oznake. Pri razredu drugo doda akustično skupino, razlog izbire in napoved prejšnjega modela. Kontrolne vsote izrezov povežejo vsako poznejšo odločitev s točno določenim zvokom.

Učenje je potekalo na osebnem računalniku, ne na mikrokrmilniku. Izhodiščni uravnoteženi učni nabor je vseboval po 192 posnetkov za vsak razred, skupaj 1.152 posnetkov iz zbirk ESC-50 in FSD50K [12, 2]. Pri razbitju stekla smo široko oznako *Glass* nadomestili z izrecno oznako *Shatter*. S tem smo izločili primere rokovanja, cingljanja in udarcev ob steklo, pri katerih do razbitja sploh ne pride, zaradi česar ne predstavljajo nevarnosti. Izbira posnetkov je upoštevala tudi izvirnega nalagatelja, zato se viri za učenje in razvojno preverjanje pri tem razredu ne prekrivajo.

Kratka dogodka, kakršna sta strel in razbitje stekla, bi se v daljšem po-

snemku lahko izgubila med številnimi spektrogramskimi izseki brez ciljnega dogodka. Zato smo zanj izdelali posebno povečanje učnih podatkov. Program najprej poišče čas dogodka, nato izreže enosekundno okno in ga z majhnim naključnim zamikom postavi na različna mesta. Pri strelah uporabi najmočnejše 20-milisekundno energijsko območje ter ohrani najmanj 620 milisekund signala po dogodku. Če se strel pojavi na samem začetku posnetka, manjkajoči del okna dopolni z ničlami na levi strani in ne zavrže začetka dogodka. Pri posnetkih razbitja stekla program določi čas dogodka na podlagi hitre spremembe energije in frekvenčne vsebine zvoka. Če je tako izbrani dogodek za več kot 18 decibelov tišji od najglasnejšega kratkega odseka v posnetku, program uporabi položaj tega najglasnejšega odseka. S tem zmanjša možnost, da bi izrez vseboval predvsem tih odmev namesto dejanskega razbitja stekla.

Iz vsakega izbranega posnetka kratkotrajnega dogodka smo pripravili šest različic. Spreminjali smo položaj dogodka in ojačenje, uporabili blago frekvenčno filtriranje, ponavljanje in dodajanje tihega ozadja iz varnih razredov zbirke ESC-50.

Pred učenjem smo po vnaprej določenem postopku poslušali 12 povečanih primerov strel in 12 primerov razbitja stekla. Med pregledom ocena izrezovanja in napoved modela nista bili prikazani. Za vsak primer smo ločeno označili, ali je dogodek značilen, netipičen ali napačen, ali je celovit oziroma odrezan ter ali je njegova glasnost primerna. Program je pred predvajanjem preveril kontrolno vsoto datoteke in vsak odgovor takoj shranil. Vseh 24 primerov je vsebovalo celovit dogodek, 23 jih je bilo značilnih, eden pa netipičen, vendar veljaven. Šele po uspešnem pregledu je program dovolil začetek učenja.

Predhodni šestrazredni seznam je vseboval 4.032 učnih zapisov: 384 za pasji lajež, po 1.344 za razbitje stekla in strel, 192 za sireno, 576 za govor ter 192 za nevihto. Za končni sedemrazredni model smo dodali 630 različnih virov razreda drugo, zato je učni seznam obsegal 4.662 zapisov. Viri novega razreda so bili razdeljeni v devet akustičnih skupin: visoki tonski zvoki, plo-

skanje in aplavz, impulzivni zvoki, kovinski in krhki zvoki, človeški zvoki brez govora, druge živali, vreme in ozadje, gospodinjski in mehanski zvoki ter glasba. Vsaka skupina je prispevala 70 učnih virov. Od skupno 630 virov jih je bilo 404 izbranih kot zahtevnih negativnih primerov, ki jim je prejšnji model pripisal visoko oceno enega od ciljnih razredov, 226 pa s ponovljivim psevdonaključnim izborom za večjo raznolikost. Pri zahtevnih primerih je bil uporabljen trisekundni izsek okoli dela posnetka, ki je prejšnji model najbolj zmedel.

Tudi ta izbor je bil preverjen s poslušanjem brez prikaza napovedi in ocen modela. Pri vsakem kandidatu smo označili, ali jasno sodi v razred drugo, ali vsebuje ciljno nevarnost oziroma razumljiv govor ter ali je njegova glasnost primerna. Postopek je potekal v devetih zaporednih krogih in je ustvaril 128 ocen kandidatov. Neustrezen ali dvoumen vir smo zamenjali in pregled ponovili; učenje je bilo dovoljeno šele, ko v zadnjem krogu ni ostal noben neustrezen primer.

Končni razvojni nabor vsebuje 413 posnetkov: po 60 posnetkov pasjega laježa, razbitja stekla in nevihte, 54 posnetkov strel, 135 posnetkov razreda drugo, 20 siren ter 24 govornih posnetkov. Med 630 učnimi in 135 razvojnimi viri razreda drugo ni prekrivanja. Prav tako so bili po identiteti vira izločeni vsi posnetki, rezervirani za končni fizični preizkus. Povečane različice kratkotrajnih dogodkov so bile uporabljene samo za učenje in so podedovale skupino svojega izvirnega posnetka.

Število zapisov v učnem seznamu ni enako številu spektrogramskih izsekov, saj daljši posnetki pri pripravi učnih podatkov ustvarijo več vhodnih oken kot krajši. Zato smo poleg povečanja podatkov za kratkotrajna dogodka zapise pasjega laježa enkrat ponovili, zapise govora pa dvakrat. S tem nismo ustvarili novih zvočnih signalov, temveč smo obstoječim virom povečali pogostost vzorčenja med učenjem. Namen je bil približno uravnotežiti število spektrogramskih izsekov, pri čemer noben izvorni posnetek ni bil odstranjen in razdelitev med učnim ter razvojnim delom ni bila spremenjena. Tako nastanejo navedene velikosti razredov: iz 192 osnovnih zapisov pasjega laježa

384 zapisov, iz 192 zapisov govora 576 zapisov ter iz 192 osnovnih zapisov vsakega razreda kratkotrajnih dogodkov po 1.344 zapisov, ker se vsakemu viru doda šest povečanih različic.

Učenje se ni začelo že z nastankom seznama. Zagonski program ga je dovolil šele po slušnem pregledu razreda drugo ter preverjanju kakovosti signala in števila spektrogramskih izsekov. Pregled vseh 765 učnih in razvojnih datotek razreda drugo ni odkril močnega amplitudnega odrezovanja. Končni seznam je ustvaril 12.679 izsekov oziroma od 1.550 do 2.068 na razred. Razmerje 1,33 je ostalo pod dovoljeno mejo 1,5, razred drugo pa je s 1.584 izseki presegel zahtevano spodnjo mejo 1.550.

4.3.2 Učenje, kvantizacija in izbira končne različice

Med učenjem so bili zvočni posnetki pretvorjeni v enake logaritemske melove spektrograme kot na napravi. Prednaučeni del YAMNet-1024 je ostal nespremenjen, učila pa se je nova polno povezana zaključna plast s sedmimi izhodi. Parameter je utež ali pristranskost, ki vpliva na rezultat mreže. Celoten model ima 3.224.519 parametrov, vendar jih je bilo učljivih le 7.175 v novi zaključni plasti: $1.024 \cdot 7$ uteži in sedem pristranskosti. Parametri prednaučenega izločevalnika značilk so ostali nespremenjeni.

Uporabili smo optimizator Adam [8], začetno hitrost učenja 0,001, skupine po 16 primerov in največ 60 prehodov čez podatke. Adam prilagaja velikost spremembe posameznih parametrov, en prehod pa pomeni obdelavo celotnega učnega nabora. Po petih prehodih brez izboljšanja razvojne pravilnosti se je hitrost prepolovila; po 12 se je učenje ustavilo in obnovilo najboljše uteži. Končno učenje se je zaključilo po 20 prehodih.

Razvoj je potekal v štirih zaporednih korakih. Najprej smo uporabljali YAMNet-256, nato pa smo ob nespremenjenih učnih in razvojnih podatkih prešli na YAMNet-1024. S tem smo lahko ločeno opazovali vpliv večjega izločevalnika značilk. V zadnjem koraku smo ohranili YAMNet-1024 ter izboljšali izbiro in povečanje učnih podatkov za kratkotrajne dogodke. Primerjava v tabeli 4.3 zato predstavlja razvojne različice sistema. Razlike med začetnim

YAMNet-256 in končnim YAMNet-1024 ne smemo pripisati samo velikosti modela, saj se končna različica razlikuje tudi po pripravi učnih podatkov. Zadnji korak je dodal učni razred drugo in ponovno naučil zaključno plast s sedmimi izhodi.

Prve tri različice so bile ovrednotene na istem nespremenjenem razvojnem naboru z 278 posnetki. Sedemrazredna različica je zaradi novega razreda uporabljala razširjeni razvojni nabor s 413 posnetki, zato njenega deleža ni mogoče neposredno primerjati z deleži v tabeli 4.3. Razvojni rezultati so bili uporabljeni za izbiro modela in niso predstavljeni kot končna ocena delovanja fizičnega sistema. Večjo različico smo izbrali, ker je namenski pospeševalnik omogočal njeno izvajanje znotraj časovnega in pomnilniškega proračuna, podrobne meritve pa so predstavljene v poglavju 6.

Tabela 4.3: Razvojni rezultati treh zaporednih šestrazrednih različic na istem naboru 278 posnetkov.

Lastnost	Začetni YAMNet-256	Vmesni YAMNet-1024	Izboljšani YAMNet-1024
Dolžina vektorja značilnk	256	1.024	1.024
Skupno število parametrov	136.646	3.223.494	3.223.494
Število učljivih parametrov	1.542	6.150	6.150
Velikost kvantiziranega modela v bajtih	184.280	3.462.018	3.462.018
Pravilno razvrščeni razvojni posnetki	242 od 278	244 od 278	246 od 278
Makro mera F_1	0,858	0,871	0,876

Končni sedemrazredni model ima 3.224.519 parametrov in je na razširjenem razvojnem naboru pravilno razvrstil 333 od 413 posnetkov. Njegova

makro mera F_1 je znašala 0,806. Ta rezultat vključuje zahtevnejši razred drugo in zato ni neposredno nadaljevanje zadnje vrstice tabele 4.3.

Po učenju smo izvedli kvantizacijo po učenju [6]. Uteži in vmesni tenzorji podprtih operacij so zapisani z osembitnimi celimi števili, zunanji vhod modela je predznačen osembitni tenzor, sedem izhodnih ocen pa ostane v 32-bitnem zapisu s plavajočo vejico. Končni model je shranjen v obliki Open Neural Network Exchange z izrecnimi operacijami kvantizacije in dekvantizacije. Datoteka je velika 3.463.059 bajtov in je označena z 256-bitno kriptografsko zgoščevalno vrednostjo, kar omogoča nedvoumno povezavo med učenjem, pretvorbo in različico na napravi.

4.3.3 Pretvorba za nevronski pospeševalnik

Za namestitev smo uporabili ST Edge AI Core, uradno orodje za analizo, pretvorbo in izvajanje modelov na napravah STM32 [16]. Različica 4.0.1 je iz modela pripravila statične opise omrežja in programsko kodo v jeziku C, razporedila operacije med procesorsko jedro in Neural-ART ter ustvarila ločeno binarno datoteko uteži velikosti 3.280.545 bajtov. Ločitev aplikacije in uteži omogoča njuno zapisovanje v različni področji zunanjega bliskovnega pomnilnika.

Poročilo prevajalnika navaja 71.146.316 operacij množenja in seštevanja za en prehod modela. Ena taka operacija pomnoži vhod z utežjo in rezultat prišteje delni vsoti. Podatek opisuje računsko zahtevnost omrežja, ne pa časa izvajanja, saj lahko pospeševalnik več operacij izvede vzporedno. Dejanski čas je odvisen tudi od razporeditve operacij, dostopov do pomnilnika in frekvence, zato je izmerjen ločeno v poglavju o rezultatih.

4.4 Izvajanje modela na Neural-ART

Procesorsko jedro še vedno vodi celoten program, Neural-ART pa izvede računsko najzahtevnejše plasti nevronske mreže. Orodja ST model pretvorijo in pripravijo razpored za takšno delitev [18].

Ob zagonu aplikacija inicializira izvajalno okolje, ustvari kontekst omrežja in preveri število ter obliko vhodnega in izhodnega tenzorja. Nato pridobi kazalca na vhodni in izhodni medpomnilnik ter iz opisa vhodnega tenzorja prebere kvantizacijski korak in ničelno točko. Predobdelava zato piše neposredno v vhodno območje, ki ga uporablja prevedeno omrežje; dodatno kopiranje celotnega spektrograma ni potrebno.

Kontekst omrežja hrani stanje in pomnilniške naslove konkretnega primerka modela, tenzor pa je večrazsežno polje števil. Vhodni tenzor vsebuje 96 časovnih korakov in 64 melovih frekvenčnih pasov. Skupno število vrednosti spektrograma je zato

$$96 \cdot 64 = 6144.$$

Izhodni tenzor vsebuje sedem ocen. Kvantizacijski korak in ničelna točka določata pretvorbo vhodnih vrednosti v osembitni zapis, kazalca pa omogočita, da predobdelava piše neposredno na naslov, s katerega jih prebere model.

Ko je vhod pripravljen, aplikacija pokliče sinhrono izvajanje omrežja. Z vidika glavne zanke to pomeni, da funkcija vrne nadzor šele, ko je na voljo vseh sedem izhodov. Tak način poenostavi nadaljnje odločanje, ker odločitveni filter ne more prebrati delno izračunanega rezultata. Čas izvajanja se meri s števcem ciklov procesorskega jedra in se shrani med diagnostične merilne podatke. Število ciklov se pretvori v čas z znano frekvenco procesorskega jedra.

Prevedeni razpored je razdeljen na 34 zaporednih odsekov izvajanja. Devetindvajset odsekov se izvede v celoti strojno, pet pa programsko. Iz števila odsekov ni mogoče izračunati odstotka strojnega pospeševanja, saj posamezni odseki ne vsebujejo enakega števila operacij. Podatek vseeno potrjuje, da večino strukture omrežja prevajalnik lahko preslika na Neural-ART, hkrati pa ohrani programsko pot za nepodprte ali pomožne operacije.

Za začasne rezultate omrežja je prevajalnik rezerviral 245.760 bajtov notranjega pomnilnika, kar vključuje tudi vhodni in izhodni medpomnilnik.

Programska koda, zajem zvoka, predobdelava, filtriranje odločitev in risanje zaslona se izvajajo na procesorskem jedru. Takšna delitev nalog je bistvo pospešene izvedbe: pospeševalnik ne nadomesti celotnega programa, ampak prevzame plastne operacije nevronske mreže, medtem ko procesorsko jedro skrbi za vhod, nadzor in uporabniško izkušnjo.

4.5 Razporeditev pomnilnika in zanesljiv za- gon

Plošča uporablja več ločenih pomnilniških območij, zato končne slike ni bilo mogoče zapisati kot eno datoteko na poljuben naslov. Aplikacija, uteži, aktivacije in zaslonska medpomnilnika imajo različne zahteve glede velikosti, hitrosti in dostopa. Tabela 4.4 prikazuje njihovo razporeditev, izkoriščenost pa je ovrednotena v poglavju 6.

Tabela 4.4: Razporeditev glavnih programskih delov po pomnilniku.

Vsebina	Naslovno območje ali začetek	Namen
Podpisana aplikacija	0x70100000	slika programa v zunanjem bliskovnem pomnilniku
Uteži Neural-ART	0x70180000	ločena binarna datoteka prevedenih uteži
Izvedbena slika aplikacije	0x34000400– 0x34100000	izvajanje programa iz notranjega pomnilnika
Začasne aktivacije modela	0x34350000– 0x343C0000	namensko notranje območje za Neural-ART
Prvi zaslonski medpomnilnik	0x90E80000	trenutno prikazana slika ali slika v pripravi
Drugi zaslonski medpomnilnik	0x90F3B800	skrita slika za menjavo brez trganja

Po ponastavitvi se najprej izvede nespremenjen začetni nalagalnik podjetja ST. Ta v zunanjem bliskovnem pomnilniku poišče podpisano aplikacijo, preveri njeno glavo, jo naloži v notranji pomnilnik in ji preda izvajanje. Uteži ostanejo v zunanjem bliskovnem pomnilniku in so dostopne na naslovih, ki jih je določil prevajalnik modela.

Pri prvem poskusu podpisovanja se program ni zagnal, čeprav je bilo zapisovanje v pomnilnik uspešno. Vzrok ni bil v modelu ali mikrofonu, ampak v velikosti predpone podpisane slike. Orodje je privzeto ustvarilo predpono dolžine 0x240, uporabljeni povezovalni opis in začetni nalagalnik pa sta pričakovala tabelo prekinitvenih vektorjev pri odmiku 0x400. Po nastavitvi poravnave na 0x400 je podpisana slika vsebovala pravilno 1.024-bajtno predpono in zagon je postal ponovljiv. Ta primer pokaže, da uspešno prevajanje in zapisovanje še ne zagotavljata zagonsko veljavne slike.

Vključitev zaslona je zahtevala dodatno razporeditev pomnilnika. Krmilnik zaslona neprekinjeno bere trenutno sliko, procesorsko jedro pa istočasno riše naslednjo. Če bi oba uporabljala isto območje, bi se lahko na zaslonu hkrati pojavila dela stare in nove slike. Aplikacija zato uporablja dva zaslonska medpomnilnika in njuni vlogi zamenja šele med navpičnim premorom zaslona.

Zaslon ima 800 krat 480 slikovnih točk, vsaka pa je v uporabljenem šestnajstbitnem barvnem zapisu velika dva bajta. En medpomnilnik zato zasede $800 \cdot 480 \cdot 2 = 768.000$ bajtov, oba skupaj pa 1.536.000 bajtov. Takšna poraba bi občutno zmanjšala notranji pomnilnik, ki ga potrebujejo tudi aplikacija in začasni rezultati modela. Medpomnilnika sta zato postavljena v zunanji pomnilnik HyperRAM, na zaporedni območji z začetkoma 0x90E80000 in 0x90F3B800. Območji sta znotraj prvega 16-mebibajtnega dela pomnilnika in se ne prekrivata z nevronskega modelom.

Krmilnik zaslona bere pomnilnik samostojno, zato dostop procesorskega jedra do pomnilnika še ne zagotavlja, da ga lahko bere tudi krmilnik. Zanj in za njegove plasti smo zato nastavili varna privilegirana dovoljenja. Brez njih bi procesorsko jedro lahko narisalo sliko, krmilnik zaslona pa je ne bi

mogel prikazati.

Zaslon potrebuje tudi slikovno uro, ki določa hitrost pošiljanja slikovnih točk. Četrta fazno sklenjena zanka pripravi uro 50 MHz, delilnik z vrednostjo dve pa slikovno uro 25 MHz. Izhodiščna zvočna aplikacija te zanke ni potrebovala in jo je pustila izključeno, čeprav jo je krmilnik zaslona izbral kot vir. Diagnostika je zato potekala zaporedno: preverjanje zunanjega pomnilnika, dovoljenj za dostop in nazadnje vira ure. Zaslon je pravilno deloval šele po ureditvi vseh treh plasti.

4.6 Časovno filtriranje in zavračanje negotivih vhodov

Izhod nevronskega modela je sedem ocen za trenutni zvočni blok. Pred nadaljnjo obdelavo se ocena nevihte prišteje razredu drugo, nevihta pa se odstrani iz razvrščanja. Tako zamrznjeni model ostane nespremenjen, uporabniška odločitev pa vsebuje šest razredov. Največja ocena se lahko med zaporednimi bloki spremeni tudi pri istem dogodku, zlasti kadar je zvok tih, kratek ali podoben drugemu razredu. Med model in uporabniški vmesnik smo zato dodali odločitveni filter z glajenjem, histerezo in pragovi po razredih.

Za vsak razred najprej izračunamo eksponentno drseče povprečje

$$s_t = 0,65p_t + 0,35s_{t-1}, \quad (4.3)$$

kjer je p_t trenutna izhodna ocena modela, s_t pa glajena ocena. Pri prvem aktivnem bloku se glajene ocene inicializirajo neposredno z izhodi modela. Po izračunu se razredi uredijo po padajoči glajeni oceni; tri najvišje vrednosti se posredujejo zaslonu in diagnostičnemu izhodu.

Tabela 4.5 prikazuje pragove po razredih. Nižji izstopni prag od vstopnega ustvari histerezo, ki preprečuje preklapljanje tik ob eni mejni vrednosti. Razredi imajo različne pragove in različno število zahtevanih zaporednih

aktivnih blokov. Kratek pasji lajež in razbitje stekla se lahko potrdita v enem bloku, strel in sirena pa potrebujeta dva. Razred drugo potrebuje tri zaporedne bloke, da ne bi prehitro prekril pravkar zaznane nevarnosti.

Globalne nastavitve filtra so delež novega bloka 0,65 v eksponentnem drsečem povprečju, najmanjša prednost 0,08 za neposredno zamenjavo razreda, štirje bloki zadržanja pri prehodu iz nevarnosti v razred drugo in dva neaktivna bloka za prehod v stanje čakanja. Ocena razbitja stekla se pred primerjavo pomnoži z 1,225.

Tabela 4.5: Pragovi in zahtevano število zaporednih blokov po razredih.

Razred	Vstopni prag	Izstopni prag	Zaporedni bloki
Pasji lajež	0,40	0,30	1
Razbitje stekla	0,60	0,45	1
Strel	0,65	0,50	2
Drugo	0,23	0,18	3
Sirena	0,65	0,50	2
Govor	0,40	0,30	1

Ocena razbitja stekla se pred razvrščanjem pomnoži z 1,225. Faktor je bil določen med razvojem, ker so kratki dogodki razbitja pogosto ostali tik za razredom drugo. Pri razredu drugo velja še dodatno varovalo: dokaz se lahko zbira kot rezervna odločitev le, kadar najvišji razred ne dosega lastnega vstopnega praga. Po potrjeni nevarnosti je prehod v drugo za štiri bloke zadržan. S tem statični šum ali konec predvajanega posnetka ne izbriše nevarnosti takoj po njeni zaznavi.

Govor in drugo sta informacijska razreda in ne zakleneta nevarnostnega opozorila. Ko zbereta zahtevani dokaz, lahko nadomestita zastarel nevarnostni izhod, pri čemer razred drugo zaradi treh potrditvenih blokov reagira počasneje od govora. Če želi drug nevarnostni razred neposredno zamenjati že potrjenega, mora doseči svoj vstopni pogoj in presegati trenutno oceno za

najmanj 0,08.

Filter razlikuje tri vrste končnega stanja. Stanje čakanja pomeni, da vhodni nadzor aktivnosti v dveh zaporednih blokih ni zaznal dovolj energije. Stanje neznano pomeni, da je zvok aktiven, vendar noben sistemski razred ne doseže svojega vstopnega pogoja. Tretja možnost je potrjen razred. Ta razlika je pomembna: neznano ni osmi razred nevronske mreže, temveč zavrnitev nezanesljive napovedi, čakanje pa označuje neaktiven vhod.

Uporabniški vmesnik namenoma loči trenutno napoved od zgodovine dogodkov. Osrednji prikaz ob aktivnem zvoku sproti kaže najvišji glajeni izhod, zato se odzove že na spremembo trenutne napovedi. V zgodovino pa se vpiše potrjen dogodek; sprememba razreda znotraj iste zvočne seje se sprejme po dveh zaporednih prikaznih oknih. Tako je glavni prikaz odziven, seznam nedavnih dogodkov in zaklenjeni alarm pa sta stabilnejša.

4.7 Uporabniški vmesnik in diagnostični izhod

Končni prototip uporablja lasten neposredni uporabniški vmesnik in ne TouchGFX. Procesorsko jedro riše like, črte in besedilo v slikovni medpomnilnik, krmilnik zaslona pa ga prikaže. Tako je manj odvisnosti in več nadzora nad menjavo slike.

Zaslon ima ločljivost 800×480 slikovnih točk. Vsaka slikovna točka je shranjena v 16-bitnem barvnem zapisu RGB565, ki rdeči in modri komponenti nameni po pet bitov, zeleni pa šest. Uporabljena sta dva slikovna medpomnilnika. Program celoten nov prikaz nariše v trenutno skriti medpomnilnik, očisti ustrezno območje podatkovnega predpomnilnika in nato ob navpičnem premoru zaslona zamenja prikazani naslov. S tem se odpravi trganje in večina vidnega utripanja, ki se je pojavljalo pri risanju neposredno v trenutno prikazano sliko.

V osrednjem delu zaslona so prikazani trenutno zaznani zvok, stanje delovanja, odstotna ocena zaupanja in vodoravni stolpec, ki to oceno ponazarja.


Pod njim so tri najvišje glajene napovedi, na desni pa tri nedavne potrjene zaznave z oceno in časom. V glavi je večji čas delovanja naprave. Spodnja vrstica prikazuje zaklenjeno opozorilo oziroma navodilo za upravljanje. Fizični uporabniški gumb začasno ustavi ali nadaljuje obdelavo, fizični gumb z oznako TAMP pa potrdi in izbriše zaklenjeno opozorilo. Oznaka TAMP je tovarniška oznaka gumba za zaznavanje posega; v tej aplikaciji je gumb dobil novo, varno programsko vlogo potrditve opozorila.

Od odstotka na zaslonu ne smemo sklepati o pravilnosti celotnega sistema. Prikazana vrednost je glajena izhodna ocena modela za trenutni zvočni blok. Na primer, prikaz 90 odstotkov pomeni močno notranjo oceno za določen razred, ne pa dokaza, da je sistem v 90 odstotkih vseh resničnih primerov pravilen. Pravilnost je zato določena s posebej zasnovanim fizičnim vrednotenjem v naslednjih poglavjih.

Slika 4.1 prikazuje dve značilni stanji končne aplikacije. V levem primeru ni dovolj aktivnega zvoka in sistem čaka. V desnem primeru je potrjena sirena, zato so rezultat, ocena in spodnje opozorilo poudarjeni z barvo nevarnosti. Prikazana ocena pri sireni je primer izhoda enega zvočnega dogodka in ne rezultat celotnega vrednotenja.



(a) Stanje čakanja.



(b) Potrjena zaznava sirene.

Slika 4.1: Končni uporabniški vmesnik med čakanjem in po zaznanem dogodku.

Poleg zaslona aplikacija uporablja asinhrono serijsko povezavo s hitrostjo 14.400 bitov na sekundo. Ob spremembi odločitve pošlje kratko strukturirano sporočilo v besedilnem zapisu s pari imen in vrednosti, za vsak obdelani zvočni blok pa še strojno berljivo vrstico z oznako **AED_CSV**. Vrstica vsebuje zaporedno številko bloka, stanje vhodne aktivnosti, vsoto spektrograma, končno odločitev in njeno oceno, tri najvišje razrede z ocenami ter podatek, ali se je odločitev spremenila.

Serijski izhod ni namenjen le razhroščevanju. Orodja na osebnem računalniku so ga med fizičnimi preizkusi zajemala neposredno v datoteke, iz katerih so bili pozneje izračunani rezultati. S tem se nismo zanašali na ročno prepisovanje napisov z zaslona. Za model, prevedene uteži, podpisano aplikacijo, preizkusne sezname in posamezne zvočne dražljaje so izračunane 256-bitne kriptografske zgoščevalne vrednosti. Različico na plošči dodatno določa identifikator potrditve sprememb v repozitoriju programske kode. Tako je mogoče meritev povezati z natančno programsko različico in različico modela brez sklepanja iz imena datoteke.

Končna veriga ostane neprekinjena: mikrofona zajame zvok, predobdelava pripravi kvantizirani spektrogram, Neural-ART izvede model, časovni filter stabilizira odločitev, rezultat pa se prikaže in zabeleži za vrednotenje.

Poglavje 5

Metodologija vrednotenja

Vrednotenje loči kakovost modela od delovanja fizične naprave. Dober rezultat na datotekah še ne zagotovi, da bodo skupaj pravilno delovali zvočnik, mikrofonski predobdelava, pospeševalnik, odločitveni filter in zaslon. Tudi nekaj uspešnih prikazov na plošči samo po sebi še ni neodvisna ocena modela.

Preizkusi so sledili razvoju sistema. Rezervirani preizkus starejšega YAMNet-256 je razkril težave pri kratkotrajnih dogodkih in usmeril izboljšave. Vmesno šestizhodno izvedbo YAMNet-1024 smo nato preverili z nadzorovanim sprejemnim preizkusom. Po dodajanju razreda drugo je sledil ločeni končni fizični preizkus sedemizhodne izvedbe s 60 novimi, slušno pregledanimi posnetki. Preizkus je bil neodvisen od učenja modela, razvojnih podatkov in vrednotenja ter izbire modela in pragov. Pred njim so bili zamrznjeni protokol, vrstni red, program in model. Izraz *neodvisen* v tej analogi označuje to ločitev od razvoja, ne pa izvedbe pri zunanji ustanovi ali sodelovanja neodvisne tretje osebe.

5.1 Cilji vrednotenja

Z vrednotenjem smo želeli odgovoriti na štiri praktična vprašanja:

1. Ali celotna naprava v nadzorovanih pogojih potrdi pričakovani razred zvoka?

2. Ali govor in raznoliki zvoki razreda drugo povzročijo lažen nevarnostni alarm?
3. Kako hitro po začetku predvajanja sistem prvič potrdi pričakovani razred?
4. Kolikšna sta čas izvajanja obdelovalnih stopenj in pomnilniški odtis izvedbe?

Prva tri vprašanja spremljajo pot od zvočnika do odločitve, četrto pa primernost izvedbe za mikrokrmilnik. Čas računanja ni enak zakasnitvi zaznave. Vsak vhod obsega približno 975 ms zvoka, nova obdelava pa se zaradi prekrievanja začne vsakih 480 ms. Odločitveni filter lahko za potrditev zahteva več zaporednih blokov. Čas izvajanja modela zato ni enak času od začetka zvoka do prikaza opozorila.

5.2 Razvojni in ocenjevalni preizkusi

Posamezni preizkusi nimajo enake vloge. Razvojni podatki so služili izbiri modela, pragov in odpravljanju napak. Rezervirani podatki so bili odprti po zamrznitvi starejše izvedbe, sprejemni preizkus pa je z znanimi kanoničnimi primeri preveril različico, ki je ostala na plošči.

Vloge posameznih stopenj povzema tabela 5.1.

Razvojno preverjanje končnega modela je obsegalo 413 posnetkov, ki niso sodelovali pri učenju zaključne plasti. V njem je bilo tudi 135 primerov razreda drugo. Rezultat je bil uporabljen pri izbiri med razvojnimi različicami, zato ga obravnavamo kot razvojni rezultat. Pred fizičnimi preizkusi so bili opravljeni tudi slušni pregledi izrezov in povečanih različic. Pri strelu in razbitju stekla smo preverili, ali je dogodek res prisoten in ali ni odrezan na začetku ali koncu. Pri nevihti smo zavrnil posnetke z izrazitim visokim tonom v ozadju. S tem smo preverjali kakovost dražljajev, ne odziva naprave.

Dimni preizkus je bil kratek funkcijski pregled po spremembi programa ali modela: zagon, mikrofona, zaslon in vsi pričakovani izhodi. Ker so rezultati

Tabela 5.1: Vloga posameznih stopenj vrednotenja.

Stopnja	Namen in dovoljena razlaga
Razvojno preverjanje modela	Izbira učnega postopka in primerjava različic YAMNet-1024; končna sedemrazredna različica uporablja 413 razvojnih posnetkov in ni končna ocena.
Rezervirani fizični preizkus	Preverjanje takrat zamrznjene izvedbe YAMNet-256 na 70 prej neuporabljenih virih; rezultat velja samo za to izvedbo.
Kalibracija in dimni preizkusi	Nastavitev vhodnega praga in pragov po razredih ter preverjanje zagona, zaslona in vseh sistemskih izhodov; rezultati niso uporabljeni kot ocena pravilnosti.
Nadzorovani sprejemni preizkus	Preverjanje vmesne šestizhodne izvedbe YAMNet-1024 na odobrenih primerih in pri treh ravneh predvajanja; ne meri posploševanja na nove posnetke.
Ločeni končni fizični preizkus	Primarna ocena zamrznjene končne naprave na 60 novih virih, neodvisna od učenja modela, razvojnih podatkov in vrednotenja ter izbire modela in pragov; vključuje pravilne zaznave, prevladujoči izhod, lažne nevarnostne alarme in odzivni čas.

lahko vplivali na naslednjo razvojno odločitev, niso vključeni v končne deleže. Enako velja za nedokončano predvajanje starega nabora 70 zvokov na novi izvedbi.

5.3 Rezervirani preizkus predhodne izvedbe

Rezervirani preizkus z oznako STM32N6-HAZARD6-FINAL-001 in poskusom FE-A01 je bil pripravljen za takrat končno različico YAMNet-256. Pred prvim zajemom so bili zamrznjeni model, programska oprema, pragovi, predobdelava, seznam dražljajev, njihov vrstni red in pravila ocenjevanja. Med 70 poskusi ni bila ponovljena nobena neuspešna napoved in nastavitve niso bile spremenjene.

5.3.1 Sestava preizkusnega nabora

Preizkus je vseboval 60 pozitivnih in 10 zahtevnih negativnih primerov. Za vsak izmed šestih izhodov je bilo izbranih deset različnih izvornih posnetkov. Med izhodi so bili pasji lajež, razbitje stekla, strel oziroma streljanje, sirena, govor in nevihta. Pozitivni posnetki so izvirali iz ocenjevalnega dela zbirke Freesound Dataset 50K, ki med razvojem te izvedbe ni bil uporabljen. Negativni posnetki so izvirali iz petega dela zbirke Environmental Sound Classification 50. Vsebovali so ploskanje, trkanje po lesenih vratih, jok dojenčka, tiktakanje ure, dež, motorno žago, prasketanje ognja, avtomobilsko hupo, kašljanje in ognjemet. To niso bili tihi kontrolni primeri, temveč zvoki, ki bi se lahko zamenjali z enim od ciljnih razredov.

Izbira je bila določena s pravili nad metapodatki in ni upoštevala napovedi modela ali kasnejšega poslušanja rezultatov. Pri razbitju stekla je bila zahtevana oznaka, ki pomeni dejanski lom, pri nevihti pa oznaka za grmenje. Metapodatkovno označeni umetni streli so bili izločeni. Govor je obsegal štiri moške, štiri ženske in dva otroška posnetka. Izločeni so bili igrani, kričani, šepetani, peti, umetno ustvarjeni ali višinsko spremenjeni glasovi. Posnetki

istega ciljnega razreda so izvirali od različnih nalagalcev, s čimer smo zmanjšali odvisnost od ene snemalne seje.

5.3.2 Priprava dražljajev

Vsi viri so bili pretvorjeni v enokanalni zapis s frekvenco vzorčenja 44,1 kHz in šestnajstbitnimi celoštevilskimi vzorci. Po normalizaciji je bil samodejno izbran najmočnejši ustrezeni izsek. Neprekinjeni zvoki so uporabljali petsekundske enote, kratkotrajni dogodki pa dve sekundi dolge enote z dogodkom v sredini. Enote so bile z vnaprej določenimi premori ponovljene do skupne dolžine najmanj deset sekund.

Osnovni cilj normalizacije je bila največja efektivna vrednost v oknu dolžine 100 ms, in sicer -12 dB glede na polno digitalno območje, ter najvišji vrh -1 dB glede na polno digitalno območje. Zaradi kratkosti dogodkov je bilo razbitje stekla nato ojačeno za 3 dB, strel pa za 10 dB. Če bi ojačenje povzročilo omejevanje več kot petih odstotkov vzorcev, ga je pripravljalni program zmanjšal samo toliko, da je ostal pod to mejo. Za negativne primere so bile že pred preizkusom določene udobne absolutne ravni predvajanja, saj se njihove izvirne glasnosti močno razlikujejo.

Za vsak dražljaj so bile shranjene izvorna in izhodna kriptografska kontrolna vsota, uporabljeno ojačenje, položaj izseka, število ponovitev in delež omejevanja. Tako je bilo mogoče preveriti, da se med pripravo in predvajanjem datoteka ni spremenila.

5.3.3 Fizični pogoji in izvedba

Glasnost sistema Windows je bila nastavljena na 75 %, razdalja med zvočnikom in vgrajenim mikrofonom pa na 30 cm. Razvojna plošča in zvočnik sta med poskusom ostala na istem mestu v mirnem prostoru. Pred začetkom je bil enkrat pritisnjen gumb za ponastavitev, med preizkusom pa ponastavljanje ni bilo dovoljeno.

Slika 5.1 prikazuje uporabljeno namizno postavitvev. Merilni trak je bil

uporabljen za ponovljivo nastavitve razdalje med zvočnikom in mikrofonom na razvojni plošči. Fotografija dokumentira razporeditev opreme, ne pa posameznega rezultata preizkusa.



Slika 5.1: Preizkusna postavitve z zvočnikom, merilnim trakom in razvojno ploščo STM32N6570-DK.

Vsak zajem se je začel tri sekunde pred predvajanjem in je trajal 20 sekund. Diagnostični zapisi so bili zajeti prek serijske povezave na vratih COM3 s hitrostjo 14.400 bitov na sekundo. Vrstni red je bil sestavljen tako, da dva zaporedna poskusa nista imela istega pričakovanega izhoda. Program je izvajalcu prikazoval le oznako poskusa in napredek, napovedi pa je shranjeval samodejno. Tehnična napaka bi dovolila nadomestni zajem samo ob ohranitvi prvotnega neuporabnega zapisa; napačna napoved sama po sebi ni bila razlog za ponovitev.

5.4 Sprejemni preizkus vmesne izvedbe

Vmesno šestizhodno izvedbo YAMNet-1024 smo enkrat preverili s sprejemnim preizkusom. Oznaka preizkusa je bila STM32N6-HAZARD6-ACCEPTANCE-001, oznaka posameznega poskusa pa AT-A01. Pred začetkom so bili zamrznjeni model, podpisana programska slika, pragovi, manifest in vrstni red. Njihovo identiteto smo preverili z 256-bitnimi kriptografskimi kontrolnimi vsotami.

Preizkus je uporabil devet predhodno poslušanih in odobrenih izvornih posnetkov. Za vsakega izmed šestih modelskih izhodov je bil izbran en jasen kanoničen primer. Vsak je bil predvajan pri nominalni ravni ter po utišanju za 6 dB in 12 dB. S tem je nastalo 18 pozitivnih poskusov. Dodani so bili še trije varni negativni poskusi: dež, veter in trkanje po lesenih vratih. Ti so bili predvajani samo pri nominalni ravni, saj bi jih z dodatnim utišanjem spremenili v prelahke negativne primere. Skupaj je preizkus vseboval 21 poskusov, kot prikazuje tabela 5.2.

Tabela 5.2: Sestava nadzorovanega sprejemnega preizkusa vmesne izvedbe.

Skupina	Nominalna raven	−6 dB	−12 dB
Šest modelskih izhodov	6	6	6
Trije varni zvoki	3	0	0
Skupaj	9	6	6

Pri kratkotrajnih dogodkih je bilo posebej pomembno, kaj je zares na posnetku. Razbitje stekla je moralo biti jasno in celovito, ne le rokovanja s steklom, trka ali cingljanja. Posnetek strela je vseboval jasen posamezen strel, ki je bil v dražljaju štirikrat ponovljen. Posnetek nevihte ni vseboval prej opaženega motečega visokega tona. Ta nadzor zmanjšuje nevarnost, da bi napravo ocenjevali z napačno označenim ali vsebinsko neustreznim zvokom.

Glasnost sistema Windows je bila nastavljena na 70 %, razdalja med zvočnikom in mikrofonom pa na 30 cm. Položaj naprav se ni spreminjal, prostor

je bil čim bolj tih, razvojna plošča pa je bila pred začetkom enkrat ponastavljena. Pred vsakim predvajanjem je program tri sekunde zajemal stanje prostora, nato pa je samodejno predvajal datoteko in shranil serijske zapise. Neuspešna napoved ni bila ponovljena.

Pri pozitivnem poskusu je bil rezultat uspešen, če se je pričakovani razred med predvajanjem vsaj enkrat pojavil kot potrjena odločitev. Pri varnem zvoku je bil uspeh odsotnost potrjenega nevarnostnega razreda; izhodi *čakanje*, *neznano* in *govor* so bili dovoljeni. Primarni rezultat je delež uspešnih devetih poskusov pri nominalni ravni. Poskusi pri nižanih ravneh so sekundarno preverjali občutljivost na glasnost. Ker je bila vsaka kombinacija izvirnega posnetka in ravni predvajana samo enkrat, rezultate prikazujemo opisno in jih ne razlagamo kot oceno pravilnosti na celotni populaciji zvokov.

5.5 Ločeni končni fizični preizkus

Po dokončanju razreda drugo, pragov po razredih in polovičnega prekrivanja vhodnih oken smo pripravili novi preizkus z oznako STM32N6-HAZARD6-FINAL-003. Edini izvedeni poskus ima oznako FE4-A01. Pred začetkom so bili zamrznjeni model, uteži, podpisana aplikacija, seznam dražljajev, njihov vrstni red in pravila analize.

5.5.1 Izbira in pregled posnetkov

Pred zamrznitvijo je bil opravljen slepi slušni pregled 118 kandidatov. Med poslušanjem napovedi modela in razvojne plošče niso bile prikazane. Kandidat je bil primeren samo, če je vseboval običajen in jasno prepoznaven dogodek, če ta ni bil odrezan na začetku ali koncu, če je bila slišnost normalna ter če ni bil označen zvočni artefakt. Identitete virov so bile preverjene tudi med različnimi zbirkami. En kandidat pasjega laježa z istim izvirnim posnetkom kot v učni množici je bil zato izločen.

Iz primernih kandidatov je bilo z vnaprej določenima semenoma izbranih 60 različnih virov, po deset za vsak sistemski razred. Razredi so bili pasji

lajež, razbitje stekla, strel, drugo, sirena in govor. Nevihta ni samostojen sistemski razred, saj se njen modelski izhod pred odločanjem prišteje razredu drugo. Deset primerov razreda drugo predstavlja deset različnih vrst zvoka: alarm, aplavz, zvonec, ploskanje, računalniško tipkovnico, pok, posodo in kuhinjske pripomočke, ognjemet, trkanje ter veter. Izbira ni uporabljala napovedi končnega modela.

Od 60 izbranih virov jih je bilo 53 iz zbirke FSD50K, sedem primerov sirene pa iz zbirke UrbanSound8K [2, 13]. Zbirki sta bili v tem koraku uporabljeni samo kot vir novih dražljajev za končni fizični preizkus; ti posnetki niso sodelovali pri učenju končnega modela.

Vrstni red je bil naključno določen pod pogojem, da zaporedna poskusa nimata istega pričakovanega razreda. Vsak dražljaj je bil normaliziran na največjo efektivno vrednost v 100 ms oknu približno -42 dB glede na polno digitalno območje. Sistem Windows je ostal na 100 % glasnosti, zvočnik pa je bil 30 cm od vgrajenega mikrofona. Položaj naprav in prostor se med preizkusom nista spreminjala.

5.5.2 Izvedba in merila

Vsak zajem je trajal 15 sekund. Prve tri sekunde so bile namenjene zajemu stanja pred predvajanjem, nato je program samodejno predvajal zamrznjeno datoteko in shranil serijski dnevnik. Za primarno merilo smo uporabili samo časovno območje od začetka predvajanja naprej. Poskus je bil uspešen, če je sistem v tem območju vsaj enkrat potrdil pričakovani razred. Napačna napoved ni bila razlog za ponovitev.

Poleg primarnega merila smo za vsak poskus določili prevladujoči potrjeni izhod in čas od začetka predvajanja do prve pravilne potrditve. Prevladujoči izhod je razred z največ potrjenimi bloki; ob izenačenju odloča večja najvišja ocena. Lažni nevarnostni alarm smo merili pri govoru in razredu drugo. Pomeni vsaj en potrjeni izhod pasjega laježa, razbitja stekla, strela ali sirene po začetku predvajanja. Posebej smo prešteli poskuse z več kot enim takim blokom ter izhode, ki so nastali v treh sekundah pred predvajanjem.

Tako preneseno stanje prejšnjega poskusa ni bilo napačno pripisano novemu dražljaju.

Za skupni in razredne deleže smo izračunali Wilsonovo petindevetdesetodstotno območje zaupanja. Njegova razlaga pri samo desetih poskusih na razred je podana skupaj z drugimi omejitvami preizkusa.

5.6 Zajem podatkov in merila uspešnosti

Vdelani program je za vsak blok zapisal aktivnost vhoda, šest ocen, tri najvišje razrede, potrjeno odločitev in čase stopenj. Zajemni program je dodal model, programsko različico, pričakovani razred, glasnost, razdaljo, kontrolno vsoto dražljaja in pot do izvirnega zapisa. Izvirni dnevniki so ostali ohranjeni, analiza pa je iz njih izdelala preglednice in grafe.

Pri analizi smo uporabljali naslednja merila:

- *potrjena pravilna zaznava* pomeni, da je odločitveni filter vsaj enkrat potrdil pričakovani razred;
- *pričakovani razred na prvem mestu* pomeni, da je imel ta razred v vsaj enem aktivnem bloku najvišjo glajeno oceno, tudi če ni dosegel pogojev za potrditev;
- *aktivni blok* je blok, pri katerem je energijsko merilo preseglo vhodni prag aktivnosti;
- *lažen nevarnostni alarm* pomeni, da je sistem pri govoru ali razredu drugo potrdil enega od štirih nevarnostnih razredov;
- *delež uspešnosti* je razmerje med številom uspešnih in številom vseh poskusov v obravnavani skupini.

Shranjena je tudi najvišja ocena pričakovanega razreda. Ne imenujemo je verjetnost pravilnosti: model ni bil umerjen tako, da bi ocena 0,8 vedno pomenila osemdesetodstotno verjetnost pravilne odločitve.

Pri rezerviranem in ločenem končnem preizkusu je bilo za deleže izračunano petindevetdesetodstotno območje zaupanja po Wilsonu [21]. Za opaženi delež $\hat{p} = k/n$, število poskusov n in vrednost $z = 1,96$ sta meji

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}. \quad (5.1)$$

Pri samo desetih poskusih na razred je takšno območje široko. Zato razlike med razredi opisujemo kot opažanje v danem preizkusu in ne kot natančno oceno splošne pravilnosti. Za sprejemni preizkus območja zaupanja po razredih niso smiselna, saj tri ravni izvirajo iz istega posnetka in zato niso tri neodvisno izbrani primeri.

5.7 Merjenje časa izvajanja in pomnilnika

Čas predobdelave, sklepanja in naknadne obdelave meri vdelana programska oprema s števcem ciklov procesorskega jedra. Število ciklov se glede na frekvenco jedra pretvori v milisekunde in zapiše ob posameznem obdelanem bloku. Analiza izloči zapise, pri katerih katera izmed časovnih vrednosti manjka, ter poroča število popolnih zapisov in povprečje. Gre za telemetrijo same naprave, ne za neodvisno meritev z osciloskopom ali zunanjim signalom. Prav tako ta čas ne vključuje čakanja, da se napolni skoraj enosekundno vhodno okno, niti morebitnega čakanja na potrditev v več zaporednih blokih.

Pomnilniški odtis je bil določen iz povezovalnega zemljevida programa, poročila prevajalnika nevronskega modela in velikosti ustvarjenih binarnih datotek. Ločeno obravnavamo notranji pomnilnik aplikacije, notranje območje začasnih aktivacij nevronskega pospeševalnika, zunanji pomnilnik HyperRAM za dva zaslonska medpomnilnika ter particiji zunanjega bliskovnega pomnilnika za aplikacijo in uteži. Te velikosti pripadajo različnim fizičnim območjem, zato njihovih odstotkov ne seštevamo. Velikost datoteke z razhroščevalnimi podatki prav tako ni enaka velikosti slike, ki se zapiše na napravo.

Električne moči in porabe energije nismo merili, zato o energijskem prihranku ne podajamo številčne trditve.

5.8 Veljavnost in omejitve

Rezervirani preizkus predhodne izvedbe ima dobro ločitev med razvojnimi in ocenjevalnimi viri, vendar njegovi rezultati ne opisujejo pozneje izdelanega modela YAMNet-1024. Sprejemni preizkus uporablja le devet že poznanih izvornih posnetkov. Ločeni končni fizični preizkus uporablja nove vire in je neodvisen od učenja modela, razvojnih podatkov in vrednotenja ter izbire modela in pragov. Zato predstavlja glavni rezultat končne naprave, ne pomeni pa zunanjšega ali neodvisno izvedenega strokovnega preizkusa. Zaradi omejenega števila virov tudi ne dokazuje splošne pravilnosti v poljubnem okolju.

Fizični preizkusi so bili izvedeni z eno razvojno ploščo, njenim vgrajenim mikrofonom, enim zvočnikom, eno razdaljo in v enem prostoru. Odstotek glasnosti sistema Windows ter digitalna raven v decibelih ne predstavljata umerjene ravni zvočnega tlaka pri mikrofону. Na rezultat lahko vplivajo frekvenčni odziv zvočnika, odboji v prostoru, zunanji šum in trenutna poravnava kratkega dogodka z obdelovalnim oknom. Še posebej pri strelu in razbitju stekla lahko majhen časovni premik spremeni vsebino posameznega bloka.

Nabor razreda drugo z desetimi kategorijami je širši od treh varnih primerov sprejemnega preizkusa, vendar še vedno ne zajema vseh možnih motečih zvokov. Za močnejšo oceno v resničnem okolju bi potrebovali več novih virov in ponovitev, umerjene ravni zvoka, različne prostore in razdalje ter večurno opazovanje lažnih alarmov.

Poglavje 6

Rezultati

Med razvojem so bile ovrednotene tri izvedbe sistema, ki se razlikujejo po modelu, številu izhodov in namenu preizkusa. Njihovih rezultatov zato ne smemo obravnavati kot ponovitve istega poskusa. Predhodni izvedbi sta pokazali, kaj je treba izboljšati, glavno oceno pa daje ločeni končni fizični preizkus, neodvisen od učenja modela, razvojnih podatkov in vrednotenja ter izbire modela in pragov. Na koncu poglavja sta ločeno predstavljena še čas izvajanja in pomnilniški odtis končnega sistema.

6.1 Ločitev vrednotenih izvedb

Tabela 6.1 določa vlogo posamezne izvedbe. Izraz *modelski izhod* pomeni neposreden rezultat nevronske mreže, izraz *sistemski razred* pa odločitev, ki jo po združevanju ocen in časovnem filtriranju uporablja aplikacija.

Končni model poleg štirih nevarnostnih razredov, govora in razreda drugo vsebuje tudi izhod za nevihto. Aplikacija njegovo oceno pred odločanjem prišteje razredu drugo, zato uporabnik vidi šest sistemskih razredov. Ta preslikava v predhodnih dveh izvedbah še ni bila uporabljena.

Tabela 6.1: Izvedbe sistema, katerih rezultati nastopajo v poglavju.

Izvedba	Model in izhodi	Vloga preizkusa
Predhodna	YAMNet-256, šest izhodov	Rezervirani fizični preizkus za odkrivanje slabosti prve rešitve.
Vmesna	YAMNet-1024, šest izhodov	Sprejemni preizkus strojne in programske poti pred zadnjimi spremembami modela in odločanja.
Končna	YAMNet-1024, sedem modelskih izhodov in šest sistemskih razredov	Ločena ocena zamrznjenega končnega sistema na 60 novih posnetkih, neodvisna od učenja, razvojnih podatkov in vrednotenja ter izbire modela in pragov.

6.2 Rezultati predhodnih izvedb

6.2.1 Predhodna izvedba YAMNet-256

Rezervirani fizični preizkus je bil izveden na takrat zamrznjeni izvedbi YAMNet-256. Pričakovani razred je bil potrjen v 37 od 60 pozitivnih poskusov. Če upoštevamo samo pet takratnih nevarnostnih razredov, je bilo uspešnih 27 od 50 poskusov. Največ težav je bilo pri kratkotrajnih dogodkih, predvsem pri strelu in razbitju stekla. Model je pričakovani razred pogosto postavil na prvo mesto, odločitveni filter pa ga ni potrdil dovolj močno ali dovolj dolgo.

Med desetimi zahtevnimi negativnimi zvoki sta dva sprožila nevarnostni alarm, kratek nevarnostni izhod pa se je pojavil tudi v enem govornem poskusu. Ti rezultati so usmerili izrezovanje dogodkov, povečanje učnih podatkov in prehod na večji izločevalnik značilk. Veljajo samo za predhodno izvedbo in niso ocena končnega sistema.

6.2.2 Vmesna izvedba YAMNet-1024

Po prehodu na YAMNet-1024 je sprejemni preizkus preveril celotno pot od predvajanja zvoka do prikaza na zaslonu. Vmesna šestizhodna izvedba je uspešno opravila 18 od 21 poskusov. Vseh devet kombinacij pri nominalni ravni je bilo izvedenih enkrat, dodatni poskusi pri nižjih ravneh pa so bili namenjeni preverjanju občutljivosti na glasnost. Preizkus je potrdil delovanje naprave na znanih kanoničnih primerih, ni pa meril posploševanja na nove posnetke.

Po tem preizkusu so bili dodani samostojen modelski izhod drugo, novi učni viri in preslikava nevihte v sistemski razred drugo. Zaradi teh sprememb rezultatov vmesne izvedbe ne primerjamo neposredno z rezultati končnega preizkusa.

6.3 Končna izvedba YAMNet-1024

Končni sedemizhodni model je bil izbran na razvojnih podatkih, njegova učna zasnova in razvojna primerjava pa sta opisani v Poglavju 4. V nadaljevanju so predstavljeni rezultati zamrznjenega sistema na fizični napravi. Med 60 posnetki je bilo po deset primerov pasjega laježa, razbitja stekla, strela, razreda drugo, sirene in govora.

6.3.1 Zaznavanje pričakovanih razredov

Primarno merilo je poskus štelo kot uspešen, če je sistem po začetku predvajanja vsaj enkrat potrdil pričakovani razred. Strožje merilo je zahtevalo, da je pričakovani razred med vsemi potrjenimi izhodi tudi prevladoval. Lažni nevarnostni alarm se je meril samo pri varovalnih razredih govor in drugo. Rezultati teh treh meril so zbrani v tabeli 6.2.

V ločenem končnem fizičnem preizkusu je sistem pričakovani razred vsaj enkrat potrdil v 57 od 60 poskusov oziroma v 95,0 % primerov, pravilni razred pa je bil prevladujoči potrjeni izhod v 54 od 60 poskusov. Pri varovalnih

Tabela 6.2: Rezultati ločenega končnega fizičnega preizkusa po sistemskih razredih.

Razred	Vsaj ena pravilna potrditev	Pravilni prevladujoči izhod	Lažni nevarnostni alarm
Pasji lajež	10 od 10	10 od 10	–
Razbitje stekla	10 od 10	10 od 10	–
Strel	10 od 10	9 od 10	–
Drugo	9 od 10	9 od 10	6 od 10
Sirena	9 od 10	9 od 10	–
Govor	9 od 10	7 od 10	0 od 10
Skupaj	57 od 60	54 od 60	6 od 20


razredih se je lažni nevarnostni alarm pojavil v 6 od 20 poskusov, vseh šestkrat pri razredu drugo. Pravilna potrditev in lažni nevarnostni alarm sta se lahko pojavila v istem poskusu, zato delež 57 od 60 ni običajna klasifikacijska točnost niti število poskusov brez napačnega izhoda.

Wilsonovo petindevetdesetodstotno območje zaupanja za delež vsaj ene pravilne potrditve sega od 86,3 % do 98,3 %. Pri štirih nevarnostnih razredih je bilo uspešnih 39 od 40 poskusov. Razlika med prvima meriloma pokaže, da se je pravilni razred v nekaterih poskusih sicer pojavil, vendar ni bil najpogostejša odločitev sistema.

Matrika na Sliki 6.1 pokaže, da so se napačni prevladujoči izhodi usmerili predvsem v razbitje stekla in razred drugo. S tem dopolnjuje skupne deleže iz tabele, saj pokaže tudi vrsto zamenjave.

Trije poskusi, pri katerih pričakovani razred ni bil niti enkrat potrjen, so navedeni v tabeli 6.3.

Pri govoru in sireni je najvišja ocena pričakovanega razreda ostala pod razrednim pragom. Pok je imel drugačen vzrok: sistem ga je zaradi podobnega kratkega prehoda večkrat potrdil kot razbitje stekla. Neuspehi tako niso posledica enega samega pravila, temveč kombinacije pragov in podobnosti med zvoki.




Slika 6.1: Matrika prevladujočih potrjenih izhodov končne izvedbe.

Tabela 6.3: Neuspešni poskusi ločenega končnega preizkusa.

Poskus	Pričakovano	Vrsta vira	Prevladujoči izhod	Najvišja ocena
FE4-010	Govor	govor	Drugo	0,357
FE4-032	Drugo	pok	Razbitje stekla	0,360
FE4-058	Sirena	sirena	Drugo	0,595

6.3.2 Lažni nevarnostni alarmi

Govor v nobenem od desetih poskusov ni sprožil potrjenega nevarnostnega izhoda. Pri razredu drugo se je tak izhod pojavil v šestih od desetih poskusov, v štirih pa je trajal več kot en blok. Najizrazitejša napaka je bil pok, ki je povzročil 17 potrditev razbitja stekla. Razporeditev preostalih zamenjav prikazuje Slika 6.2.




Slika 6.2: Potrjeni nevarnostni izhodi pri desetih vrstah zvoka razreda drugo.

Pravilna potrditev razreda drugo in lažni alarm se lahko pojavita v istem poskusu. Zato devet pravih potrditev tega razreda ne pomeni, da je sistem devetkrat brez napake zavrnil nevarnost. Rezultat kaže, da končna izvedba ciljne dogodke praviloma zazna, še vedno pa težko zavrne nekatere kratke vsakdanje zvoke.

6.3.3 Čas do prve pravilne potrditve

Mediane zabeleženega časa od začetka predvajanja do prve pravilne potrditve so po razredih znašale od 1,00 s za razbitje stekla do 2,50 s za razred drugo, kot prikazuje Slika 6.3. Vrednost vključuje morebitno tišino na začetku posnetka, zbiranje vhodnega okna in časovno potrjevanje, zato je ne smemo enačiti s časom samega računanja modela. Prav tako ne gre za zunanjo meritev celotne zakasnitve z osciloskopom ali drugim neodvisnim signalom.



Slika 6.3: Mediana časa od začetka predvajanja do prve pravilne potrditve.

6.4 Čas izvajanja končne izvedbe

Čas posameznih računskih stopenj je prikazan v tabeli 6.4. Meritve pripadajo končnemu sedemizhodnemu modelu YAMNet-1024 in niso združene z meritvami predhodnih izvedb.

Nov vhodni blok se začne pripravljati vsakih 480 ms, zato računanje porabi približno 2,25 % razpoložljivega intervala. Čas 10,81 ms zato dokazuje računsko sposobnost sprotnega delovanja, ne pa odziva uporabniškega opo-

Tabela 6.4: Povprečni čas obdelave enega vhodnega bloka končne izvedbe.

Stopnja	Čas
Predobdelava	1,43 ms
Izvajanje nevronske mreže	9,38 ms
Skupaj	10,81 ms

zorila v enakem času. Preostali čas omogoča neprekinjen zajem zvoka in osveževanje zaslona. Celotni opazovani odziv je daljši, ker mora naprava pred odločanjem zbrati skoraj enosekundno vhodno okno in po potrebi potrdati več zaporednih blokov; mediane po razredih so v preizkusu znašale od 1,00 s do 2,50 s.

6.5 Pomnilniški in računski odtis končne izvedbe

Pomnilniška območja v tabeli 6.5 so fizično ločena, zato njihovih vrednosti in odstotkov ne seštevamo.

Tabela 6.5: Pomnilniški odtis končne izvedbe YAMNet-1024.

Pomnilniško območje	Uporabljeno	Na voljo	Izraba
Notranji pomnilnik aplikacije	595,1 KiB	1.023 KiB	58,2 %
Aktivacije nevronskega pospeševalnika	240,0 KiB	448 KiB	53,6 %
Zaslonska medpomnilnika v zunanjem pomnilniku	1.500,0 KiB	16.384 KiB	9,2 %
Podpisana programska slika	244,3 KiB	512 KiB	47,7 %
Prevedene uteži v zunanjem bliskovnem pomnilniku	3.203,7 KiB	64.512 KiB	5,0 %

Vsa območja ostanejo znotraj določenih omejitev. Prevajalnik je 29 od 34 delov izvajalnega načrta dodelil pospeševalniku Neural-ART, pet pa pro-

cesorskemu jedru. En prehod modela obsega 71.146.316 operacij množenja in seštevanja, izmerjeni čas izvajanja nevronske mreže pa je 9,38 ms.

Poglavje 7

Razprava in sklepne ugotovitve

7.1 Odgovori na raziskovalna vprašanja

Prvo raziskovalno vprašanje: *Ali je mogoče kvantizirani model za zaznavanje zvočnih dogodkov izvajati v realnem času na mikrokrmilniku STM32N6 z uporabo nevronskega pospeševalnika Neural-ART?*

Odgovor je pritrdilen. Kvantizirani model YAMNet-1024 se na mikrokrmilniku STM32N6 izvaja sproti. Predobdelava enega bloka traja povprečno 1,43 ms, izvajanje nevronske mreže 9,38 ms, skupaj pa 10,81 ms. Nov blok se pripravi vsakih 480 ms, zato računanje porabi približno 2,25 % tega intervala. Tudi aplikacija, aktivacije, uteži in dva zaslonska medpomnilnika ostanejo znotraj svojih pomnilniških območij. Celotna lokalna pot je torej računsko izvedljiva sproti. To ne pomeni, da uporabnik prejme opozorilo v 10,81 ms. Mediane časa od začetka predvajanja do prve pravilne potrditve so po razredih znašale od 1,00 s do 2,50 s, saj mora sistem najprej zbrati vhodno okno in po potrebi potrditi več zaporednih odločitev.

Drugo raziskovalno vprašanje: *Kakšen delež potrjenih pravilnih zaznav in lažnih nevarnostnih alarmov doseže končni sistem pri nadzorovanem predvajanju zvokov na fizični napravi?*

Odgovor daje ločeni končni fizični preizkus, neodvisen od učenja modela, razvojnih podatkov in vrednotenja ter izbire modela in pragov. Pričakovani

razred je bil vsaj enkrat potrjen v 57 od 60 poskusov, pri nevarnostnih razredih pa v 39 od 40. Pravilni razred je bil prevladujoči potrjeni izhod v 54 od 60 poskusov. Pri varovalnih razredih se je lažni nevarnostni alarm pojavil v 6 od 20 poskusov, vseh šestkrat pri razredu drugo. Ker sta se pravilna potrditev in lažni alarm lahko pojavila v istem poskusu, prvega deleža ne razlagamo kot običajno klasifikacijsko točnost. Ciljne dogodke je sistem v preizkusni postavitvi zaznaval dobro, zavračanje kratkih vsakdanjih zvokov pa ostaja njegova glavna slabost.

Tretje raziskovalno vprašanje: *Kako se posamezni zvočni razredi razlikujejo po zanesljivosti in kateri dejavniki omejujejo delovanje sistema?*

Zanesljivost ni enaka pri vseh razredih. Pasji lajež, razbitje stekla in strel so bili v končnem preizkusu potrjeni v vseh desetih poskusih. Sirena, govor in drugo so dosegli devet pravih potrditev od desetih. Rezultati neuspešnih poskusov kažejo različne vzroke: ocena govora in sirene je ostala pod razrednim pragom, kratek pok pa je bil podoben razbitju stekla. Na delovanje zato vplivajo kakovost in glasnost vira, položaj dogodka v skoraj enosekundnem oknu, podobnost med razredi ter izbrani pragovi in časovna pravila.

7.2 Razprava o uporabnosti rezultatov

Prototip je namenjen pretvarjanju izbranih nevarnih zvokov v vidno opozorilo za gluhe in naglušne uporabnike. Njegova praktična prednost je samostojno delovanje: mikrofoni, predobdelava, model, odločanje in prikaz so na isti napravi. Internetna povezava, oddaljeni strežnik in uporabniški račun niso potrebni. Običajna programska oprema surovega zvoka ne shranjuje, začasni vzorci pa se po sprotni obdelavi prepišejo. To zmanjša izpostavljenost zvoka iz domačega okolja in hkrati omogoča delovanje tudi ob izpadu omrežja.

Zaslon loči med čakanjem, nezanesljivo napovedjo, običajnim zvokom in potrjeno nevarnostjo. Prototip je s tem uporaben kot osnova za nadaljnji razvoj namenskega opozorilnega pripomočka, ni pa certificiran varnostni ali

medicinski sistem. Njegova zanesljivost je bila preverjena v nadzorovani postavitvi enega prostora.

7.3 Omejitve

V vsakem sistemskem razredu je bilo deset preizkusnih posnetkov, zato so razredna območja zaupanja široka. Zvoki so bili predvajani prek enega zvočnika na razdalji 30 cm v enem prostoru. Tak postopek zagotavlja ponovljivost, ne zajame pa odmeva, oddaljenosti, prekrivanja več zvokov in različnih mikrofonov pri vsakdanji uporabi. Uporabljeni posnetki so bili novi glede na učenje in izbiro pragov, vendar še vedno izvirajo iz javnih zbirk in ne iz daljšega terenskega snemanja ciljnega okolja.

Sistem pozna omejen nabor nevarnosti. Posebej zahtevni so kratki dogodki, ki so si spektralno podobni. Razred drugo je raznolik in ga 630 učnih virov ne more izčrpno opisati; v šestih od desetih njegovih poskusov se je zato pojavil lažni nevarnostni alarm. To je glavni negativni rezultat končnega preizkusa in neposredna utemeljitev za razširitev tega razreda ter boljše zatiranje lažnih alarmov. Čas izvajanja temelji na notranji telemetriji, celotna zakasnitev pa ni bila izmerjena z zunanjim električnim signalom. Poraba energije ni bila izmerjena, prav tako ni bila izvedena uporabniška študija z gluhih ali naglušnih osebami. Namen za ciljno skupino je zato zasnovna motivacija, ne dokaz klinične ali vsakdanje uporabnosti.

7.4 Možnosti nadaljnjega dela

Najpomembnejši naslednji korak je razširiti razred drugo z lokalnimi gospodinjskimi zvoki in s težkimi negativnimi primeri, pri katerih trenutni sistem napove nevarnost. Po novem učenju bi moral slediti popolnoma ločen končni preizkus na več razdaljah, v več prostorih, ob hrupu in ob hkratnem pojavu govora ter nevarnega dogodka. Lasten uravnotežen nabor bi pričakovano okolje opisal bolje kot zgolj javni posnetki.

Celotno zakasnitev bi bilo mogoče natančneje izmeriti z zunanjim signalom in osciloskopom, porabo pa z merilnikom energije. Za uporabniški del bi bilo treba skupaj z gluhi in naglušnimi osebami preveriti razumljivost opozoril, velikost besedila, barve ter morebitno dodajanje vibracijskega ali svetlobnega izhoda. Morebitno razširjanje nabora nevarnosti naj temelji na dovolj kakovostnih učnih podatkih in ločenem vrednotenju, ne le na dodajanju novih oznak.

7.5 Sklep

V diplomskem delu je nastal samostojen sistem za zaznavanje nevarnih zvokov na razvojni plošči STM32N6570-DK. Zvok zajame vgrajeni mikrofoni, program ga pretvori v obliko, primerno za model YAMNet-1024, nevronske pospeševalnik pa izračuna napoved, ki se po časovnem filtriranju prikaže kot vidno opozorilo. Vse poteka lokalno, brez računalniškega oblaka in brez trajnega shranjevanja surovega zvoka.

Najpomembnejši nauk razvoja je bil, da prednaučenega modela ni dovolj le namestiti na ploščo. Veliko dela je zahtevalo poslušanje in izbiranje posnetkov, izrezovanje kratkih dogodkov, povečanje učnih podatkov ter gradnja razreda drugo. Šele skupaj z razrednimi pragovi in časovnim filtriranjem je model postal uporaben na fizični napravi.

V ločenem končnem fizičnem preizkusu je končna različica pričakovani razred vsaj enkrat potrdila v 57 od 60 poskusov, pravilni razred pa je bil prevladujoč v 54 od 60. Pri varovalnih razredih se je lažni nevarnostni alarm pojavil v 6 od 20 poskusov, vseh šestkrat pri razredu drugo. Ti rezultati se ne izključujejo, saj je isti poskus lahko vseboval pravilno potrditev in lažni alarm. Obdelava vhoda, ki se pripravi vsakih 480 ms, traja 10,81 ms in ostane znotraj razpoložljivega pomnilnika, medtem ko je opazovani odziv do prve pravilne potrditve zaradi zbiranja okna in časovnega filtriranja daljši. Sistem je raziskovalni prototip, ne certificiran varnostni ali medicinski pripomoček. Rezultati pokažejo, kateri deli so že dovolj trdni ter da sta izboljšanje razreda

drugo in zatiranje lažnih alarmov najpomembnejša naslednja koraka.

Literatura

- [1] David Elliott in sod. „Tiny Transformers for Environmental Sound Classification at the Edge“. V: *arXiv preprint arXiv:2103.12157* (2021). DOI: 10.48550/arXiv.2103.12157.
- [2] Eduardo Fonseca in sod. „FSD50K: An Open Dataset of Human-Labeled Sound Events“. V: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 30 (2022), str. 829–852. DOI: 10.1109/TASLP.2021.3133208.
- [3] Jort F. Gemmeke in sod. „Audio Set: An Ontology and Human-Labeled Dataset for Audio Events“. V: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing*. 2017, str. 776–780. DOI: 10.1109/ICASSP.2017.7952261.
- [4] Shawn Hershey in sod. „CNN Architectures for Large-Scale Audio Classification“. V: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing*. 2017, str. 131–135. DOI: 10.1109/ICASSP.2017.7952132.
- [5] Andrew G. Howard in sod. „MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications“. V: *arXiv preprint arXiv:1704.04861* (2017). DOI: 10.48550/arXiv.1704.04861.
- [6] Benoit Jacob in sod. „Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2018, str. 2704–2713. DOI: 10.1109/CVPR.2018.00286.

- [7] Dhruv Jain in sod. „HomeSound: An Iterative Field Deployment of an In-Home Sound Awareness System for Deaf or Hard of Hearing Users“. V: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 2020, str. 1–12. DOI: 10.1145/3313831.3376758.
- [8] Diederik P. Kingma in Jimmy Ba. „Adam: A Method for Stochastic Optimization“. V: *3rd International Conference on Learning Representations*. 2015. URL: <https://arxiv.org/abs/1412.6980> (pridobljeno 14. 8. 2026).
- [9] Bor-Shyh Lin in sod. „IoT-Based Indoor Sound Visualization System With a Two-Layer Composite Model for Deaf or Hard-of-Hearing Individuals“. V: *IEEE Transactions on Human-Machine Systems* (2026), str. 1–10. DOI: 10.1109/THMS.2026.3706141.
- [10] Md Mohaimenuzzaman in sod. „Environmental Sound Classification on the Edge: A Pipeline for Deep Acoustic Networks on Extremely Resource-Constrained Devices“. V: *Pattern Recognition* 133 (2023), str. 109025. DOI: 10.1016/j.patcog.2022.109025.
- [11] OpenAI. *ChatGPT*. 2026. URL: <https://chatgpt.com/> (pridobljeno 27. 8. 2026).
- [12] Karol J. Piczak. „ESC: Dataset for Environmental Sound Classification“. V: *Proceedings of the 23rd ACM International Conference on Multimedia*. Association for Computing Machinery, 2015, str. 1015–1018. DOI: 10.1145/2733373.2806390.
- [13] Justin Salamon, Christopher Jacoby in Juan Pablo Bello. „A Dataset and Taxonomy for Urban Sound Research“. V: *Proceedings of the 22nd ACM International Conference on Multimedia*. Association for Computing Machinery, 2014, str. 1041–1044. DOI: 10.1145/2647868.2655045.
- [14] STMicroelectronics. *Discovery kit with STM32N657X0 MCU. User manual UM3300*. 2024. URL: <https://www.st.com/resource/en/>

- `user_manual/um3300-discovery-kit-with-stm32n657x0-mcu-stmicelectronics.pdf` (pridobljeno 9.8.2026).
- [15] STMicroelectronics. *Quantized YAMNet for Audio Event Detection*. 2026. URL: https://github.com/STMicroelectronics/stm32ai-modelzoo/tree/main/audio_event_detection/yamnet (pridobljeno 17.8.2026).
- [16] STMicroelectronics. *ST Edge AI Core Technology Documentation*. 2026. URL: <https://stm32ai-cs.st.com/assets/embedded-docs/index.html> (pridobljeno 9.8.2026).
- [17] STMicroelectronics. *STM32N6 Getting Started Audio*. 2025. URL: <https://github.com/STMicroelectronics/STM32N6-GettingStarted-Audio> (pridobljeno 9.8.2026).
- [18] STMicroelectronics. *STM32N6-AI: Artificial Intelligence Ecosystem for STM32N6*. 2026. URL: <https://www.st.com/en/development-tools/stm32n6-ai.html> (pridobljeno 9.8.2026).
- [19] TensorFlow. *Sound Classification with YAMNet*. 2023. URL: <https://www.tensorflow.org/hub/tutorials/yamnet> (pridobljeno 9.8.2026).
- [20] TensorFlow. *YAMNet Model Documentation and Source Code*. 2026. URL: <https://github.com/tensorflow/models/tree/master/research/audioset/yamnet> (pridobljeno 9.8.2026).
- [21] Edwin B. Wilson. „Probable Inference, the Law of Succession, and Statistical Inference“. V: *Journal of the American Statistical Association* 22.158 (1927), str. 209–212. DOI: 10.1080/01621459.1927.10502953.

Dodatek A

Sledljivost programske opreme in rezultatov

Končno vrednotenje ima identifikator STM32N6-HAZARD6-FINAL-003, poskus pa oznako FE4-A01. Manifest ima naslednjo kontrolno vsoto SHA-256:

```
0355fca0f9a3d26be1e41b4fd9896f7
fb7c9f567557a7dde23826dbb36c1342b.
```

Glavni rezultati in grafi so shranjeni v naslednjih imenikih:

- imenik `hazard6_final_evaluation_v4_independent` v podimeniku `experiments/results`,
- `experiments/results/deployment_footprint`.

Fotografije fizične izvedbe skupaj s kontrolnimi vsotami izvirnikov so shranjene v imeniku `Doc/thesis_photos`.

Izvorna koda, analizni programi in zapisi o razvoju so v javnem repozitoriju <https://github.com/aleksMuhicFri2/stm32n6-edge-audio-classifier>. Zaradi licenčnih omejitev in velikosti datotek javne zvočne zbirke niso vključene v repozitorij. Njihove izvirne oznake in kontrolne vsote uporabljenih posnetkov so shranjene v manifestih.